AI Usage Tracker & Optimizer — Software Requirements Specification

Phiên bản 0.10 · 05/11/2026 · @Nguyen Tran Gia Bao · Cập nhật theo báo cáo nghiên cứu hiệu suất token, kiểm tra log ngày 05/11/2026 và thiết kế lưu trữ

Lưu ý cho thành viên nhóm — BẮT BUỘC TỰ ĐỌC: Mỗi thành viên phải tự đọc toàn bộ SRS này. Không đưa tài liệu cho AI tóm tắt rồi coi như đã đọc. Bản tóm tắt của AI có thể bỏ sót ràng buộc, trạng thái "Chờ chốt" và các quyết định đã thống nhất với GV. Đọc xong, hãy để lại một comment "Đã đọc" kèm ít nhất một câu hỏi hoặc góp ý ở phần mình phụ trách.

Cách đọc bản v0.10: các phần thay đổi so với v0.8 được đánh dấu MỚI v0.9, SỬA v0.9, MỚI v0.10 hoặc SỬA v0.10. Các phần vẫn chờ nhóm chốt được đánh dấu CHỜ CHỐT.

1. Thông tin tài liệu

Bản v0.9 cập nhật theo kết quả nghiên cứu cách đo hiệu suất sử dụng token và lần kiểm tra log thứ hai (05/11/2026): đề xuất cụ thể cho FR-ANLY-003, kiểm tra định dạng Claude Code, bổ sung phát hiện về log Codex và Antigravity, bỏ ràng buộc desktop phải viết bằng Flutter.

Trường	Giá trị
Document ID	SRS-AUTO-001
Phiên bản	0.10
Ngày	2026-11-05
Trạng thái	Draft — chờ nhóm duyệt FR-ANLY-003 (OQ-03) và kiểm tra Claude Code CLI trên máy thật
Nền tảng	Android (Flutter) + desktop companion .NET 10 / Avalonia UI (Windows, Linux) + Firebase SỬA v0.10
Provider MVP	Antigravity, Codex CLI, Claude Code (đọc log usage cục bộ trên máy tính)
Ghi chú xử lý	[passage omitted]

1.1 Lịch sử phiên bản

Phiên bản	Ngày	Nội dung
0.10	2026-11-05	Chốt lưu trữ lai: SQLite trên desktop (thêm bảng source_files, sessions, daily_local, sync_queue), Firestore một document mỗi ngày (`users/{uid}/daily/{date}`); hàng đợi offline bằng SQLite; desktop .NET 10 + Avalonia, truy cập Firebase qua REST; thêm kết luận "Chưa thấy khác biệt"; thêm R-10, OQ-13; đóng OQ-09
0.9	2026-11-05	Viết lại FR-ANLY-003 theo báo cáo nghiên cứu (trạng thái task, quy trình so sánh 6 bước, luật kết luận); thêm FR-ANLY-004 (chi phí ngầm), entity TaskOutcome và EfficiencyReport; cập nhật PoC Claude Code và phát hiện mới về Codex, Antigravity; mở allowlist cho `.jsonl.zst`; desktop không bắt buộc Flutter; thêm R-07–R-09, OQ-09–OQ-12
0.8	2026-11-02	Chốt OQ-02, 04–08; kiến trúc Firebase Spark, desktop xử lý; thêm FR-AIKEY-001; chuẩn hóa token theo PoC (§10.4); sửa công thức total và cost
0.7	2026-11-02	Mở rộng MVP sang Antigravity, Codex CLI, Claude Code; thêm FR-SRC-001; thêm provider vào dữ liệu và analytics; bỏ yêu cầu phi chức năng; viết lại toàn bộ FR theo Figma (thêm FR-DEMO, FR-ACT, FR-COST-002, FR-PRIV, FR-EXP, FR-DSET; Session đổi thành UsageEvent; mã ghép nối 6 ký tự; cảnh báo 70/90/100%; bộ lọc Day/Week/Month/Total)
0.6	2026-11-02	Rà soát toàn bộ: sửa state machine, bổ sung entity Session/BudgetAlert/SyncJob, chốt công thức cached/thinking token, quy tắc múi giờ, cơ chế yêu cầu sync, kênh cảnh báo, bảo mật pairing, NFR desktop, retention, RTM đầy đủ
0.5	2026-10-31	Đồng bộ daily summary, permission error và Analytics interface với project attribution
0.4	2026-10-31	Thu gọn MVP, bỏ quota, lịch reset, thông tin gói; bổ sung project attribution
0.3	2026-10-31	Thêm desktop companion, chuyển nguồn MVP sang Antigravity local usage
0.2	2026-10-31	Chuyển MVP sang Gemini-first, rút gọn core feature
0.1	2026-10-31	Bản SRS Codex-first ban đầu

1.2 Thay đổi chính so với v0.8

v0.10 MỚI v0.10

- **Lưu trữ lai được chốt** (§6): chi tiết ở SQLite trên desktop; Firestore chỉ một document mỗi ngày và `efficiency/current`, khoảng 2 lượt ghi mỗi lần sync, để vừa hạn mức gói Spark.
- **Desktop .NET 10 + Avalonia UI** (OQ-09 đóng). Không có SDK Firestore cho người dùng cuối trên .NET nên desktop dùng REST với Firebase ID token và tự làm hàng đợi offline trong SQLite (FR-SYNC-002, §7.3).
- **Nhận yêu cầu sync:** chờ spike chọn gRPC Listen hoặc poll (OQ-13, R-10).
- **FR-ANLY-003:** thêm kết luận "Chưa thấy khác biệt" khi đủ mẫu nhưng không trục nào khác rõ.

v0.9

- **FR-ANLY-003 có đề xuất cụ thể** thay cho khung 4 tầng: trạng thái kết quả của task suy ra từ metadata (§4.4), quy trình so sánh 6 bước có kiểm tra cỡ mẫu, khoảng tin cậy và độ ổn định, luật ra kết luận thay cho Efficiency Index. Vẫn chờ nhóm duyệt (OQ-03).
- **Thêm FR-ANLY-004 — Chi phí ngầm:** tách riêng token của phiên phụ (Codex `guardian_review`, sub-agent Claude Code, model phụ chạy nền).
- **Thêm entity** TaskOutcome (SQLite) và EfficiencyReport (Firestore); bổ sung trường cho UsageEvent và DailySummary (§6).
- **PoC Claude Code:** đã kiểm tra định dạng trên một phiên Claude Agent SDK; có `thinking_tokens`, cache ghi tách 5 phút/1 giờ, dòng `cost-state` có chi phí USD; một phản hồi bị ghi thành nhiều dòng (§10.4). Máy Linux của nhóm chưa cài Claude Code CLI.
- **Codex:** file cũ nén `.jsonl.zst`, có file trên 500 MB, file rẽ nhánh hai ID; thêm vào allowlist và yêu cầu đọc theo luồng (FR-DATA-001, §7.3).
- **Antigravity:** lần kiểm tra 05/11 thấy thư mục `conversations/` rỗng, không có số token cục bộ; thêm R-08 và OQ-10.
- **Desktop không bắt buộc Flutter** (§3.4); mobile vẫn Flutter Android. (v0.10 chốt .NET 10 + Avalonia.)
- **FR-RECO-001:** LLM gợi ý chỉ giải thích và khuyên dựa trên số liệu, không quyết định setup nào tốt hơn.

2. Giới thiệu

2.1 Mục đích

AI Usage Tracker & Optimizer (tên sản phẩm µToken) giúp người dùng biết mình dùng LLM nhiều hay ít, tốn bao nhiêu và dùng có hiệu quả không. Hệ thống gồm ứng dụng mobile làm dashboard chính và desktop companion đọc usage của Antigravity, Codex CLI và Claude Code trên máy tính. Hệ thống phân tích token, model, project, thời gian, hiệu suất và chi phí ước tính, không bao giờ tải prompt, response hay source code lên cloud.

Tài liệu dành cho các thành viên nhóm phát triển, giảng viên hướng dẫn và người kiểm thử.

2.2 Phạm vi MVP

Trong phạm vi

- Đăng nhập Google trên mobile và desktop, ghép nối bằng mã 6 ký tự; chế độ xem demo không cần đăng nhập.
- Desktop tự phát hiện Antigravity, Codex CLI, Claude Code và đọc token metadata từ log cục bộ theo allowlist; hỗ trợ cả người dùng trả theo API key lẫn gói subscription.
- Desktop: Overview, Activity, Sources, Sync, Settings và các trạng thái lỗi.
- Đồng bộ dữ liệu tổng hợp từ desktop lên tài khoản, có hàng đợi khi mất kết nối.
- Mobile: Tokens, Analytics, Insights, Settings; usage theo ngày và project; chi tiết chi phí; bảng giá model.
- Hiệu suất quy trình (cache, context, suy luận, lỗi, chi phí ngầm) và hiệu suất kết quả theo đề xuất FR-ANLY-003 CHỜ CHỐT.
- Ngân sách tháng với cảnh báo 70/90/100% qua thông báo trên máy tính và điện thoại.
- Recommendation kèm mức tiết kiệm tiềm năng do skill ai-usage-optimizer sinh ra.
- Xuất CSV/JSON, xóa dữ liệu, ngôn ngữ, định dạng số, chu kỳ sync.

Ngoài phạm vi

Hạng mục	Lý do	Hướng xử lý
Tool khác (Cursor, GitHub Copilot, Gemini CLI…)	Giới hạn MVP	Thêm connector sau khi ba nguồn MVP ổn định
Usage qua API chính thức (OpenAI, Anthropic)	Cần admin key, rủi ro lưu key	Connector chạy trên backend, sau MVP
Chat trên web (chatgpt.com, claude.ai)	Không có nguồn usage chính thức	Không triển khai
Mobile-only không cài companion	Usage nằm trên máy tính	Không hỗ trợ trong MVP
Lưu prompt, response, source code	Không cần cho analytics, rủi ro riêng tư	Không triển khai
Realtime từng giây	Không cần cho analytics	Đồng bộ theo lịch và khi refresh
Tự động đổi model	Recommendation chỉ tư vấn	Sau MVP
Quota còn lại, lịch reset, thông tin gói	Không cần cho mục tiêu ban đầu	Không triển khai (log Codex có `rate_limits`, để dành sau MVP)
Mức bình thường gộp nhiều người dùng MỚI v0.9	Cần đồng ý chia sẻ và server tổng hợp	Sau MVP; MVP chỉ dùng lịch sử của chính người dùng (OQ-12)
Thí nghiệm có kiểm soát (chạy cùng bộ task trên nhiều model) MỚI v0.9	Cần môi trường benchmark riêng	Sau MVP; MVP chỉ phân tích usage thật

Dòng "Chỉ số hiệu suất kết quả (success rate, cost per successful task) — đánh giá lại sau PoC" của v0.8 được chuyển vào phạm vi dưới dạng đề xuất FR-ANLY-003, vì PoC ngày 05/11 cho thấy log đủ tín hiệu để suy ra trạng thái task (§10.4). SỬA v0.9

Thứ tự ưu tiên khi mâu thuẫn: SRS này → Idea Draft → Technical Design → Báo cáo nghiên cứu hiệu suất token → trao đổi miệng/chat.

2.3 Thuật ngữ

Thuật ngữ	Ý nghĩa
Usage	Token, model, project, thời gian và metadata hiệu suất của các phiên Antigravity, Codex CLI, Claude Code
Session	Một cuộc chat/phiên làm việc trong một nguồn; trên UI gọi là "chat"
Turn MỚI v0.9	Một lượt người dùng hỏi, tính tới khi agent dừng; có thể gồm nhiều usage event
Task MỚI v0.9	Một việc người dùng muốn hoàn thành; MVP coi mỗi turn có thay đổi file hoặc chạy lệnh là một task, các turn hỏi lại trong ≤ 2 phút gộp vào task trước (OQ-03)

Usage event	Một request tới model trong một session, đơn vị thu thập nhỏ nhất; hiển thị trên màn Activity của desktop
Phiên phụ (side session) Mới v0.9	Phiên do tool tự tạo, người dùng không trực tiếp tương tác: Codex `thread_source = guardian_review`, sub-agent Claude Code (`isSidechain`), model phụ chạy nền
Chi phí ngầm Mới v0.9	Chi phí của phiên phụ
Setup (cách dùng) Mới v0.9	Tổ hợp được so sánh: nguồn + model + mức suy luận (effort)
Nhóm việc (task group) Mới v0.9	Phân loại task theo metadata (Small, Medium, Large) để chỉ so sánh trong cùng nhóm
SR, CPST Mới v0.9	Success rate = task thành công ÷ task đã xác định; Cost per successful task = tổng chi phí ÷ số task thành công
MDE Mới v0.9	Minimum detectable effect: chênh lệch SR nhỏ nhất phát hiện được với cỡ mẫu hiện có (§10.1)
Nguồn (provider)	Tool AI mà companion đọc usage: antigravity, codex (Codex CLI), claude_code (Claude Code). Trên UI hiển thị theo Figma: Gemini, Codex, Claude
Desktop companion	Ứng dụng chạy trên máy tính, đọc dữ liệu local, xử lý và gửi dữ liệu tổng hợp
Pairing	Ghép nối mobile và desktop bằng mã/QR dùng một lần
Cached token	Phần input token được provider đọc từ cache; là tập con của input token (sau chuẩn hóa)
Thinking token	Token suy luận nội bộ của model; tính phí như output token; là tập con của output token
Estimated cost	Chi phí quy đổi từ token theo bảng giá API có version; không phải hóa đơn thật, không phản ánh gói subscription
Ngày người dùng	Ngày lịch theo múi giờ người dùng đã chọn
Stale data	Dữ liệu chưa đồng bộ thành công quá 24 giờ
Auto-sync threshold	Dữ liệu cũ hơn 15 phút thì mobile tự yêu cầu sync khi mở dashboard
Skill	Workflow AI phân tích aggregate usage và sinh recommendation

2.4 Tham chiếu

- Idea Draft (`../../ideas/ai-token-usage-manager/draft.md`)
- Báo cáo nghiên cứu "Đo hiệu suất sử dụng token từ log cục bộ của các công cụ lập trình AI", bản nháp 05/11/2026 Mới v0.9
- Tài liệu khoa học dùng làm căn cứ cho FR-ANLY-003: Kapoor và cộng sự 2024 (AI Agents That Matter); Miller 2024 (Adding Error Bars to Evals); Yao và cộng sự 2024 (τ-bench); Wang và cộng sự 2023; Zheng và cộng sự 2023; Panickssery và cộng sự 2024 Mới v0.9
- TokenTracker · Tokenly Android · Antigravity — cài đặt và xác thực

3. Mô tả tổng quan

3.1 Kiến trúc

Firebase dùng gói Spark (miễn phí): chỉ Authentication và Firestore, không có Cloud Functions hay Cloud Messaging phía server. Vì vậy desktop companion làm toàn bộ xử lý: đọc log, lưu UsageEvent và TaskOutcome trong SQLite cục bộ, tính DailySummary (một document mỗi ngày), chi phí, chỉ số hiệu suất và báo cáo so sánh (EfficiencyReport), kiểm tra ngân sách, rồi ghi kết quả tổng hợp lên Firestore qua hàng đợi trong SQLite. SỬA v0.10 Mobile đọc Firestore, ghi yêu cầu (sync, cài đặt, ngân sách) và tự gọi LLM để tạo gợi ý bằng API key người dùng lưu trên điện thoại. Firestore Security Rules chỉ cho truy cập `users/{uid}` của chính người dùng. SỬA v0.9

Thành phần	Nhiệm vụ
Desktop	Tìm log → đọc theo luồng, chỉ giữ số → chuẩn hóa thành UsageEvent → suy ra TaskOutcome → tính chỉ số, so mức thường, gắn cờ, so sánh setup → ghi DailySummary, EfficiencyReport, BudgetAlert lên Firestore
Firestore	Kênh trung gian duy nhất giữa desktop và mobile; chỉ chứa dữ liệu tổng hợp
Mobile	Hiển thị dashboard; gọi LLM (key của người dùng) để giải thích và gợi ý; thông báo cục bộ

3.2 Core feature

1. Đăng nhập và ghép nối mobile–desktop.
2. Tự phát hiện Antigravity, Codex CLI, Claude Code trên máy tính và bật/tắt từng nguồn.
3. Thu thập, chuẩn hóa và đồng bộ usage theo phiên, model, project.
4. Dashboard token, model, project, chi phí và hiệu suất (quy trình, kết quả, so sánh setup).
5. AI recommendation.
6. Ngân sách và cảnh báo.
7. Quản lý kết nối và dữ liệu.

3.3 Người dùng

Người dùng	Loại	Đặc điểm	Cách tương tác
Cá nhân dùng AI coding tool	Human	Dùng Antigravity, Codex CLI hoặc Claude Code trên máy tính, xem dashboard trên điện thoại	Mobile app + desktop companion
AI Usage Optimizer	AI Agent	Chỉ đọc aggregate usage và EfficiencyReport, ghi recommendation; không tự tính số, không chọn setup	Skill chạy trong app mobile, đầu ra JSON có schema SỬA v0.9

3.4 Ràng buộc

- Mobile viết bằng Flutter, là giao diện chính và chỉ hỗ trợ Android. Desktop companion viết bằng **.NET 10 (C#) + Avalonia UI** để chạy trên Windows và Linux; truy cập Firebase Auth và Firestore qua REST API với Firebase ID token của người dùng (không dùng SDK server, vì SDK server bỏ qua Security Rules). SỬA v0.10
- Firebase gói Spark: chỉ dùng Authentication (Google) và Firestore; không dùng Cloud Functions, không gửi FCM từ server. Mọi tính toán chạy trên desktop.
- Companion chỉ được mở file trong allowlist đã khai báo (§7.3); không đọc, không lưu provider credential.
- Companion được đọc transcript local để trích metadata, nhưng transcript, prompt, response, lệnh terminal và source code không được rời máy. Tên lệnh chỉ được đọc trên máy để nhận diện lệnh test/build; chỉ lưu kết quả đúng/sai (FR-ANLY-003). SỬA v0.9
- Mỗi tài khoản có tối đa một desktop companion đang kết nối; companion đó đọc tối đa ba nguồn (Antigravity, Codex CLI, Claude Code).
- Mọi dữ liệu cô lập theo Firebase UID.
- Metric không có trong nguồn hiển thị "Không có dữ liệu", không mặc định bằng 0.
- Desktop companion hỗ trợ Windows 10+ trước, sau đó Linux (Ubuntu) (máy demo của nhóm chạy Linux); mobile chỉ hỗ trợ Android 9+.
- Kết luận so sánh hiệu suất chỉ được hiển thị khi qua các bước kiểm tra của FR-ANLY-003; không đủ bằng chứng thì hiển thị "Chưa đủ dữ liệu", không xếp hạng. MỚI v0.9

3.5 Giả định

- Ít nhất một trong ba tool đã cài, đăng nhập (API key hoặc gói subscription) và phát sinh usage trên desktop.
- Người dùng cho phép companion đọc thư mục dữ liệu của các nguồn đã bật.
- USD là tiền tệ tính toán; múi giờ mặc định lấy từ thiết bị mobile.
- Người dùng chọn model không ngẫu nhiên; vì vậy so sánh model chỉ là quan sát, không phải thí nghiệm (§10.5). MỚI v0.9

3.6 Rủi ro

ID	Rủi ro	Ảnh hưởng	Giảm thiểu
R-01	Claude Code CLI chưa được kiểm tra trên máy thật SỬA v0.9	Parser có thể thiếu trường hoặc khác phiên bản	Định dạng đã kiểm tra trên phiên Claude Agent SDK (§10.4); nhóm kiểm tra lại `~/.claude/projects` trên máy có CLI trước khi khóa parser
R-02	Định dạng log đổi sau khi tool cập nhật; Antigravity lưu protobuf không có schema công khai	Parse sai, số liệu sai	FR-SYNC-003: parser có version, kiểm tra tổng token theo phép cộng ở §10.4, gặp format lạ thì dừng ghi
R-03	Đọc dữ liệu nội bộ của tool	Rủi ro điều khoản	GV đã chấp nhận đọc dữ liệu cục bộ qua desktop app; chỉ đọc file của chính người dùng, không gọi API ẩn
R-04	Chi phí ước tính không phản ánh người dùng trả theo gói	Budget gây hiểu nhầm	Ghi rõ "ước tính theo giá API" trên mọi màn hình cost
R-05	Model của ba nguồn thiếu trong bảng giá (ví dụ `codex-auto-review`)	Cost bị đếm thiếu	Bảng giá phủ mọi model đang dùng; báo thiếu giá trên UI
R-06	Không có server gửi push (Firebase Spark)	Cảnh báo ngân sách đến trễ khi app Android bị hệ điều hành tắt nền	Desktop hiện thông báo ngay; mobile hiện thông báo cục bộ khi nhận dữ liệu (FR-NOTI-001); nâng lên FCM nếu sau này dùng gói Blaze
R-07 MỚI	Trạng thái thành công suy ra từ metadata có thể sai	SR, CPST lệch; kết luận so sánh sai	Chỉ dùng trạng thái "có bằng chứng" cho SR chính; SR phụ để kiểm tra độ nhạy; hiển thị số task chưa xác định; kiểm chứng trên mẫu có người gán nhãn (OQ-03)
R-08 MỚI	Antigravity không giữ file hội thoại cục bộ (thư mục `conversations/` rỗng ngày 05/11)	Thiếu số token Antigravity	Nguồn hiển thị "Không có dữ liệu" thay vì 0; tìm nguồn thay thế (transcript theo workspace, hook) — OQ-10
R-10 MỚI v0.10	Desktop .NET không có listener Firestore chính thức; poll `sync_requests` tốn lượt đọc của gói Spark (poll 60 giây ≈ 1.440 lượt/ngày/người)	Giới hạn số người dùng; "Sync now" chậm	Spike gRPC Listen với Firebase ID token (OQ-13); nếu không được thì poll 60–120 giây và chỉ poll khi Connection Connected
R-09 MỚI	Người dùng có quá ít task để so sánh	Phần lớn kết luận là "Chưa đủ dữ liệu"	Hiển thị tiến độ (số task còn thiếu); chỉ số quá trình vẫn dùng được với ít dữ liệu

4. Yêu cầu chức năng

Mỗi FR gồm ưu tiên (P0 bắt buộc cho MVP, P1 nên có), mô tả, quy tắc dữ liệu và tiêu chí nghiệm thu dạng Given/When/Then. Cột “Figma” chỉ màn hình chuẩn: M = mobile, S = trạng thái mobile, O = overlay, D = desktop.

4.1 Onboarding, xác thực và ghép nối

FR-AUTH-001 — Đăng nhập Google · P0 · Figma M01, D01

Mô tả	Mobile và desktop shall đăng nhập bằng cùng tài khoản Google qua Firebase Auth. Mobile xử lý các trạng thái đang đăng nhập, người dùng hủy, thất bại, mất mạng và hết phiên. Đăng xuất ở màn Account (M13).
Quy tắc dữ liệu	`google_id_token` bắt buộc, còn hiệu lực; sai hoặc hết hạn → AUTH_INVALID
Nghiệm thu	Given tài khoản hợp lệ, when đăng nhập, then app tạo phiên theo UID và chỉ tải dữ liệu của UID đó. Given phiên hết hạn, then app hiện trạng thái “Session expired” và nút đăng nhập lại.

FR-DEMO-001 — Chế độ xem demo · P1 · Figma M01

Mô tả	Màn Welcome shall có nút “View demo” mở dashboard với dữ liệu mẫu cố định, không cần đăng nhập, không gọi Firebase.
Quy tắc dữ liệu	Dữ liệu demo đóng gói trong app, gắn nhãn “Demo” trên mọi màn hình
Nghiệm thu	Given chưa đăng nhập, when chọn View demo, then app hiển thị Tokens, Analytics, Insights với dữ liệu mẫu và không có thao tác ghi nào được gửi lên server.

FR-CONN-001 — Ghép nối desktop · P0 · Figma M02, M03, D03

Mô tả	Mobile shall hiển thị mã ghép nối dùng một lần (nút Copy code, đếm ngược 10 phút) và hướng dẫn cài desktop. Desktop đã đăng nhập cùng tài khoản nhập mã để hoàn tất ghép nối.
Quy tắc dữ liệu	`pairing_code` : 6 ký tự chữ hoa/số (bỏ 0, O, 1, I), hiển thị dạng XXX — XXX, dùng một lần, hết hạn sau 10 phút. Mobile ghi mã vào `users/{uid}/pairing` ; desktop (đã đăng nhập cùng tài khoản) đọc và so khớp, Firestore Rules tự chặn tài khoản khác. Sai → PAIRING_INVALID; hết hạn → PAIRING_EXPIRED; đã dùng → PAIRING_USED. Desktop đăng nhập khác tài khoản với mobile → ACCOUNT_MISMATCH.
Nghiệm thu	Given mã hợp lệ, when desktop xác nhận, then Connection chuyển Connected và mobile chuyển sang trạng thái chờ usage đầu tiên (S02). Given đã có máy khác đang kết nối, then mobile hiện trạng thái “Existing desktop” và yêu cầu ngắt máy cũ trước. Given desktop không phản hồi trong 30 giây, then hiện “Desktop no response” với nút thử lại.

FR-CONN-002 — Quản lý kết nối · P0 · Figma M10, D07

Mô tả	Mobile shall hiển thị tên máy, trạng thái kết nối, thời điểm sync gần nhất, token theo từng nguồn, trạng thái background sync, cam kết không thu prompt, nút Sync now và Disconnect. Desktop shall hiển thị điện thoại đã ghép nối, lần sync gần nhất, dung lượng đã truyền, lịch sử sync (thời gian, thiết bị, số event, dung lượng, kết quả), nút Disconnect và Pair new device.
Quy tắc dữ liệu	`connection_id` : UUID bắt buộc; không thuộc UID → RESOURCE_NOT_FOUND
Nghiệm thu	Given Connection đang Connected, when ngắt kết nối từ mobile hoặc desktop, then Connection chuyển Revoked, desktop dừng ghi lên Firestore trong ≤ 5 giây và dữ liệu lịch sử được giữ.

4.2 Nguồn và thu thập (desktop)

FR-SRC-001 — Phát hiện và quản lý nguồn · P0 · Figma D05, D06, D10

Mô tả	Desktop shall tự phát hiện ba nguồn khi khởi động và khi bấm “Rescan sources”. Màn Sources hiển thị mỗi nguồn: trạng thái, token, tỉ trọng, thời điểm event gần nhất; bảng phạm vi thu thập (token, model, thời điểm: có cho Codex và Claude Code, Antigravity tùy dữ liệu sẵn có; thinking: Codex, Claude Code, Antigravity; thời lượng phản hồi: chỉ Codex; lỗi lệnh/tool: Codex, Claude Code; prompt, response: không bao giờ); đường dẫn log của từng nguồn; nút Manage permissions. Màn chi tiết nguồn hiển thị token, chi phí ước tính, cache rate, chi phí ngầm, event gần nhất, xu hướng theo ngày, phân bổ model và tình trạng thu thập (quyền đọc log, parse metadata, lần đọc thành công gần nhất). SỬA v0.9
Quy tắc dữ liệu	`provider` ∈ {antigravity, codex, claude_code}; khác → PROVIDER_INVALID. Trạng thái nguồn ∈ {Connected, Not found, Permission missing, Update required, No usage data}. “No usage data” khi tìm thấy thư mục nguồn nhưng không có file chứa token (ví dụ Antigravity, R-08). SỬA v0.9
Nghiệm thu	Given máy có Codex CLI và Claude Code nhưng không có Antigravity, when quét, then hai nguồn Connected và Antigravity Not found. Given hệ điều hành thu hồi quyền đọc log một nguồn, then desktop hiện trạng thái “Log access needs attention” kèm hướng dẫn cấp lại quyền, các nguồn khác vẫn thu thập và dữ liệu cũ của nguồn đó vẫn giữ. Given thư mục Antigravity tồn tại nhưng `conversations/` rỗng, then nguồn hiển thị “No usage data”, không hiển thị 0 token.

FR-DATA-001 — Thu thập usage event · P0 · Figma D04 SỬA v0.9

Mô tả	Desktop shall đọc log cục bộ của các nguồn đang bật, chuẩn hóa theo §10.4 và lưu UsageEvent vào SQLite trên máy: thời điểm, nguồn, model, mức suy luận (effort, nếu có), session, turn, input, cached, cache write, output, thinking token (nếu có), thời gian phản hồi (nếu có), trạng thái, project và cờ phiên phụ. Desktop đồng thời ghi tín hiệu kết quả của từng turn vào TaskOutcome (FR-ANLY-003). Event mới xuất hiện trong vài giây sau khi tool ghi log. UsageEvent và TaskOutcome không được upload; chỉ DailySummary và EfficiencyReport lên Firestore (FR-DATA-002). Prompt, response, lệnh terminal, kết quả lệnh và source code không bao giờ được lưu hay upload. Yêu cầu đọc file: đọc từng dòng (streaming), không nạp cả file; giải nén `.jsonl.zst` khi đọc; ghi nhớ vị trí đã đọc (offset) theo file để lần sau chỉ đọc phần mới; bỏ nội dung ngay khi đọc. Log Codex có thể lớn hơn 500 MB.
Quy tắc dữ liệu	Token là số nguyên ≥ 0; `cached_tokens + cache_write_tokens ≤ input_tokens`; `thinking_tokens ≤ output_tokens`; sai → METRIC_INVALID. Khóa chống trùng = (`provider`, `source_event_id`): Codex dùng `response_id`, Antigravity dùng id trong gen_metadata, Claude Code dùng `message.id`. Claude Code ghi một phản hồi thành nhiều dòng cùng `usage` (mỗi khối thinking, text, tool_use một dòng): desktop shall gộp theo `message.id` và chỉ tính usage một lần. `is_side_session` = true khi Codex `thread_source = guardian_review` hoặc có `source.subagent`, hoặc Claude Code `isSidechain = true`.
Nghiệm thu	Given cùng log được đọc lại 10 lần, then số liệu không bị cộng trùng. Given một lượt Codex có input 30,764 (cached 5,504) và output 142 (reasoning 79), then event lưu total = 30,906. Given một phản hồi Claude Code xuất hiện ở 3 dòng cùng `message.id`, then chỉ có 1 UsageEvent. Given file `.jsonl.zst`, then event được đọc như file thường. Given file log 500 MB, then desktop đọc xong mà bộ nhớ dùng không tăng theo kích thước file. Given người dùng gửi một prompt trong Codex CLI, then event xuất hiện trên màn Activity của desktop.

FR-SYNC-003 — Kiểm soát định dạng log · P0 · Figma D-states "Collector update required"

Mô tả	Desktop shall nhận diện định dạng log của từng nguồn bằng parser có version riêng. Gặp định dạng không nhận diện được, desktop dừng ghi dữ liệu của nguồn đó và yêu cầu cập nhật collector.
Quy tắc dữ liệu	Log không khớp parser → SOURCE_FORMAT_UNSUPPORTED
Nghiệm thu	Given log có cấu trúc lạ, when quét, then không có event nào được ghi từ log đó, nguồn chuyển Update required và dữ liệu cũ giữ nguyên.

FR-ACT-001 — Activity trên desktop · P1 · Figma D02, D04

Mô tả	Desktop shall hiển thị Overview (tổng token, chi phí ước tính, cached, chi phí ngầm, lần sync gần nhất, hoạt động sync gần đây, tỉ trọng nguồn, tình trạng riêng tư) và màn Activity: danh sách event có lọc theo nguồn, model, khoảng thời gian, trạng thái (Collected/Warnings), loại phiên (chính/phụ), tìm kiếm theo model, nguồn hoặc event ID, và khung chi tiết event (nguồn, model, input, cached, output, latency, chi phí). SỬA v0.9
Quy tắc dữ liệu	Khoảng thời gian ∈ {last 24h, 7 days, 30 days}
Nghiệm thu	Given chọn lọc Codex và last 24h, then danh sách chỉ còn event Codex trong 24 giờ qua.

4.3 Đồng bộ

FR-SYNC-001 — Đồng bộ theo yêu cầu · P0 · Figma M10, S03, S04

Mô tả	Mobile shall ghi yêu cầu sync vào `users/{uid}/sync_requests` khi mở tab Tokens nếu lần sync gần nhất cũ hơn chu kỳ sync, và khi bấm refresh hoặc Sync now. Desktop nhận yêu cầu mới (gRPC Listen hoặc poll ≤ 60 giây, OQ-13), đọc log mới, cập nhật DailySummary và EfficiencyReport rồi đánh dấu yêu cầu hoàn tất. SỬA v0.10 Trong khi chờ, mobile hiển thị S03.
Quy tắc dữ liệu	`trigger` ∈ {screen_open, manual_refresh}; khác → TRIGGER_INVALID. Đang có yêu cầu chưa xong thì không tạo yêu cầu mới
Nghiệm thu	Given desktop online, when bấm Sync now, then dữ liệu mới hiển thị và last sync cập nhật. Given desktop không phản hồi trong 30 giây, then mobile hiện S04 kèm Retry sync và Desktop connection, dữ liệu cũ vẫn hiển thị.

FR-SYNC-002 — Đồng bộ nền và hàng đợi · P0 · Figma D12, M09

Mô tả	Desktop shall thu thập liên tục khi đang chạy (kể cả khi đóng cửa sổ, nếu bật Background collection) và ghi DailySummary đã thay đổi lên Firestore theo chu kỳ người dùng chọn. Khi mất kết nối, desktop giữ các document chưa đẩy trong bảng `sync_queue` của SQLite, hiển thị số event đang chờ theo nguồn và tự đẩy khi có mạng lại (thử lại với khoảng chờ tăng dần). Desktop chỉ ghi document có thay đổi. SỬA v0.10
Quy tắc dữ liệu	`sync_interval_minutes` ∈ {5, 15, 30, 60}, mặc định 15
Nghiệm thu	Given mất mạng trong lúc có 18 event mới, when có mạng lại, then DailySummary của các ngày liên quan được cập nhật đúng một lần và hàng đợi về 0.

FR-DATA-002 — Tổng hợp theo ngày · P0 SỬA v0.9

Mô tả	Desktop shall tính DailySummary theo ngày người dùng (múi giờ thiết bị), nguồn, model và project từ UsageEvent cục bộ, kèm chi phí ước tính theo PricingVersion; số chat = số session khác nhau; tách riêng token và chi phí của phiên phụ; đếm task theo trạng thái kết quả (FR-ANLY-003). Mỗi ngày người dùng là **một document** `users/{uid}/daily/{YYYY-MM-DD}` chứa tổng và map breakdown theo khóa `provider|model|project_key`, ghi đè khi tính lại; kích thước < 900 KB. SỬA v0.10 Desktop đồng thời tính EfficiencyReport 30 ngày (FR-ANLY-003) và ghi đè document `efficiency/current`.
Quy tắc dữ liệu	N/A
Nghiệm thu	Given event thay đổi, when tính lại, then document của ngày đó bị ghi đè, không cộng chồng. Given người dùng ở UTC+7, when có event lúc 01:00 giờ địa phương, then event thuộc ngày địa phương đó.

4.4 Tokens, Analytics, hiệu suất và chi phí (mobile)

FR-DASH-001 — Tab Tokens · P0 · Figma M04, S01–S04

Mô tả	Tab Tokens shall hiển thị bộ lọc thời gian, tổng token, chi phí ước tính, thanh tỉ lệ input/output/cached, bốn chỉ số nhanh (7 ngày, 30 ngày, trung bình ngày, cached), thẻ tỉ trọng theo nguồn kèm số model, biểu đồ xu hướng theo ngày trong tháng, liên kết "Full report". Chạm vào chi phí mở bảng chi tiết chi phí (O03). Khi chưa ghép nối hiển thị S01; khi đã ghép nối nhưng chưa có usage hiển thị S02.
Quy tắc dữ liệu	`period` ∈ {day, week, month, total}; khác → PERIOD_INVALID. Total = toàn bộ dữ liệu từ khi bắt đầu
Nghiệm thu	Given chọn Month, then mọi số liệu trên màn hình tính trong tháng hiện tại theo ngày người dùng. Given dữ liệu stale, then app vẫn hiển thị dữ liệu cũ kèm nhãn stale và nút refresh.

FR-ANLY-001 — Usage details và Daily usage · P0 · Figma M04B, M06

Mô tả	Usage details shall hiển thị top model (token, tỉ trọng), heatmap hoạt động theo ngày, danh sách ngày gần đây (số chat, token) và "See all days". Daily usage shall có hai tab Daily và Project, mỗi dòng gồm ngày hoặc project, tổng token, số chat.
Quy tắc dữ liệu	Theo công thức §10.1
Nghiệm thu	Given input 100 (trong đó cached 40) và output 20 (trong đó thinking 10), then total token = 120; cached và thinking không được cộng thêm.

FR-ANLY-002 — Tab Analytics · P0 · Figma M05

Mô tả	Tab Analytics shall hiển thị bộ lọc thời gian, tổng token, chi phí, tỉ lệ input/output, bảng model (nguồn, token, tỉ trọng) và chi phí 7 ngày gần nhất kèm % thay đổi so với 7 ngày trước.
Quy tắc dữ liệu	`period` như FR-DASH-001
Nghiệm thu	Given metric không được nguồn cung cấp, then app hiển thị "Không có dữ liệu" thay vì 0.

FR-ANLY-003 — Hiệu suất sử dụng token (Efficiency) · P0 · Figma M05 (dòng Efficiency), M05B, M05C · CHỜ CHỐT — OQ-03 VIẾT LẠI v0.9

Trạng thái: đề xuất v2, thay cho khung 4 tầng của v0.8, dựa trên báo cáo nghiên cứu ngày 05/11/2026. Nhóm cần duyệt các điểm ở cuối mục này. Phần đánh dấu "(giả định)" là lựa chọn của nhóm chưa có nghiên cứu trực tiếp, cần hiệu chỉnh bằng dữ liệu thật.

Mục tiêu	Tính năng cốt lõi: cho biết token được dùng hiệu quả đến đâu (kết quả thu được trên chi phí bỏ ra) và setup nào hiệu quả, ổn định hơn — chỉ khi dữ liệu đủ chắc.
Định nghĩa hiệu suất	Hiệu suất = chi phí cho mỗi task thành công (CPST), luôn đọc cùng tỷ lệ thành công (SR) và độ ổn định. Không đánh giá bằng số token hay số tiền đơn lẻ.
A. Chỉ số quá trình	Chỉ cần metadata, dùng được ngay với ít dữ liệu: cache hit rate, context growth, thinking share, error rate (lệnh/tool lỗi), retry rate, tokens per turn so với trung vị, hidden cost share (FR-ANLY-004). Mỗi chỉ số có nhãn Good/Review theo bảng ngưỡng bên dưới; cần ≥ 5 chat trong kỳ mới gắn nhãn.
B. Trạng thái kết quả của task	Desktop suy ra cho mỗi task một trong năm trạng thái, lưu ở TaskOutcome: • **verified_success**: lệnh test/build cuối cùng sau lần sửa file cuối có exit code 0; không có turn lỗi. • **verified_failure**: turn kết thúc bằng lỗi hoặc bị hủy (Codex `task_complete.error`, `turn_aborted`); hoặc lệnh test/build cuối thất bại. • **likely_success**: có sửa file, không lỗi, người dùng không hỏi lại trong ≤ 2 phút. • **likely_failure**: ≥ 3 lệnh/tool lỗi liên tiếp, hoặc người dùng hỏi lại trong ≤ 2 phút. • **undetermined**: không có tín hiệu nào ở trên. Lệnh test/build được nhận diện từ tên lệnh (ví dụ `pytest`, `npm test`, `flutter test`, `cargo build`) ngay trên máy; chỉ lưu kết quả đúng/sai, không lưu lệnh. Không đọc git log, không dùng nút 👍👎 trong MVP.
C. Chỉ số kết quả	SR chính = verified_success ÷ (verified_success + verified_failure). SR phụ = (verified + likely success) ÷ (tổng trừ undetermined), dùng để kiểm tra kết luận có đổi khi nới tiêu chí. CPST = tổng chi phí ÷ số task thành công. Kèm: P50 và P90 chi phí mỗi task, tỷ lệ task phải làm lại, số task undetermined.
D. So sánh setup — 6 bước	Desktop chỉ đưa ra kết luận so sánh khi qua lần lượt: 0. **Cùng công cụ.** So model trong cùng nguồn. So khác nguồn thì ghi rõ là so bộ "công cụ + model", vì mỗi công cụ có chi phí riêng (ví dụ phiên tự duyệt của Codex). 1. **Cùng nhóm việc.** Chỉ so trong cùng nhóm Small/Medium/Large; chênh lệch tính trong từng nhóm rồi mới gộp. 2. **Đủ mẫu.** Mỗi setup ≥ 20 task trong nhóm và MDE ≤ 20 điểm phần trăm; không đạt → "Chưa đủ dữ liệu" kèm tiến độ (giả định). 3. **Hai trục.** Xét đồng thời SR và CPST; setup bị setup khác vượt trên cả hai trục nằm ngoài biên Pareto. 4. **Chênh lệch có thật.** Khoảng tin cậy 95% của chênh lệch SR, sai số tính theo phiên (cụm); khoảng chứa 0 thì không kết luận về SR. CPST dùng khoảng tin cậy bootstrap theo phiên. 5. **Ổn định.** SR theo tuần, P90 ÷ P50 chi phí mỗi task, tỷ lệ làm lại. Gắn cờ "kém ổn định" khi SR theo tuần dao động quá 10 điểm hoặc P90 ÷ P50 > 3 (giả định).

E. Luật kết luận	<table><tr><th>Kết luận</th><th>Điều kiện</th></tr><tr><td>Tốt hơn</td><td>Không kém rõ trên trục nào (theo khoảng tin cậy), tốt hơn rõ trên ít nhất một trục</td></tr><tr><td>Rẻ hơn, chưa thấy kém</td><td>CPST thấp hơn rõ; khoảng tin cậy chênh lệch SR chứa 0; hiển thị kèm MDE</td></tr><tr><td>Đánh đổi</td><td>Tốt hơn rõ một trục, kém rõ trục kia; hiển thị chi phí cho mỗi điểm SR tăng thêm</td></tr><tr><td>Kém hơn</td><td>Kém rõ ít nhất một trục và không tốt hơn rõ trục nào (bị setup kia vượt theo Pareto) SỬA v0.10</td></tr><tr><td>Chưa thấy khác biệt MỚI v0.10</td><td>Đủ mẫu nhưng không trục nào khác rõ; hiển thị kèm MDE</td></tr><tr><td>Chưa đủ dữ liệu</td><td>Không qua bước 2</td></tr></table> Mức chắc chắn: **cao** khi MDE ≤ 10 điểm, **trung bình** khi 10–20 điểm (giả định).
F. Bỏ Efficiency Index	Đề xuất bỏ chỉ số `EI = SR / (CPST / CPST trung vị)` của v0.8, vì gộp hai trục thành một số làm mất thông tin đánh đổi và không có khoảng tin cậy. Thay bằng luật kết luận ở mục E.
Màn hình	M05 có dòng “Efficiency” hiển thị SR chính (± khoảng tin cậy) hoặc “Chưa đủ dữ liệu”, chạm mở M05B. M05B (30 ngày): thẻ Outcome (SR chính, SR phụ, CPST và xu hướng, P50/P90 chi phí mỗi task, tỷ lệ làm lại, số task chưa xác định), thẻ Process (chỉ số mục A có nhãn, gồm chi phí ngầm), lối vào “Compare setups”, định nghĩa task thành công, liên kết “See suggestions” sang M07. M05C Compare setups: chọn nguồn và nhóm việc, bảng setup gồm SR ± khoảng tin cậy, CPST, cờ ổn định, chip kết luận và mức chắc chắn; setup chưa đủ dữ liệu hiển thị tiến độ “n/20”; thẻ “Best pick” chỉ xuất hiện khi có setup đạt “Tốt hơn” hoặc “Rẻ hơn, chưa thấy kém”. **Figma M05B, M05C cần cập nhật theo mô tả này.**
Quy tắc dữ liệu	Chỉ số nguồn không cung cấp hiển thị “—”. Mẫu số bằng 0 → “Không có dữ liệu”. Chỉ số kết quả tính trên phiên chính; phiên phụ được cộng vào chi phí của setup tạo ra nó.
Nghiệm thu (đề xuất)	Given turn Codex sửa file rồi chạy `pytest` với exit code 0 và không có lỗi turn, then TaskOutcome = verified_success. Given setup có 12 task trong nhóm Small, then M05C hiển thị “Chưa đủ dữ liệu · 12/20”, không xếp hạng. Given A: 60 task, SR 85%, CPST $0,42 và B: 60 task, SR 82%, CPST $0,18 trong cùng nguồn và nhóm, then B có kết luận “Rẻ hơn, chưa thấy kém”, MDE ≈ 19 điểm, mức chắc chắn trung bình. Given so sánh hai setup khác nguồn, then nhãn hiển thị “So sánh công cụ + model”. Given Claude Code không có lệnh test trong task, then task là likely hoặc undetermined, không phải verified.

Ngưỡng đề xuất cho chỉ số quá trình (giả định, hiệu chỉnh khi có dữ liệu thật):

Chỉ số	Trả lời câu hỏi	Good	Review	Nguồn có dữ liệu
Cache hit rate	Có tận dụng cache không?	≥ 50%	< 50% sau lần gọi thứ 3	Codex, Claude Code (Antigravity nếu có)
Context growth (trung vị)	Chat có phình to không?	≤ 3×	> 5× hoặc > 70% cửa sổ context	Như trên
Thinking share	Có suy luận quá nhiều không?	≤ 2× mức thường của người dùng	> 2× ở task Small	Codex, Claude Code, Antigravity
Error / retry	Có lỗi lặp không?	Retry ≤ 5%	≥ 3 lỗi liên tiếp hoặc retry > 10%	Codex, Claude Code
Tokens per turn (so với trung vị 30 ngày)	Lượt gần đây có tốn hơn thường không?	≤ +20%	> +50%	Cả 3
Chi phí mỗi task	Task có “cháy” tiền không?	≤ 3× trung vị	> 3× trung vị	Có giá
Hidden cost share	Phiên phụ tốn bao nhiêu?	≤ 30%	> 30%	Codex, Claude Code

Căn cứ: chỉ báo tỷ lệ thành công gây hiểu sai vì thử lại nhiều lần đủ làm điểm tăng; agent có độ chính xác tương đương chênh nhau gần 100 lần về chi phí (Kapoor 2024). Khoảng 200 câu chỉ phát hiện chắc chênh lệch từ 13 điểm; sai số theo cụm có thể lớn gấp 3 (Miller 2024). gpt-4o thành công 61% ở một lần thử nhưng dưới 25% khi phải đúng cả 8 lần (Yao 2024). Chi tiết ở báo cáo nghiên cứu, Bảng 12.

Các điểm nhóm cần chốt (OQ-03): (1) định nghĩa task và quy tắc gộp turn; (2) danh sách lệnh test/build và việc đọc tên lệnh trên máy; (3) luật chia nhóm Small/Medium/Large; (4) ngưỡng 20 task và MDE 20 điểm; (5) bỏ Efficiency Index; (6) ngưỡng chỉ số quá trình; (7) cập nhật Figma M05B, M05C.

FR-ANLY-004 — Chi phí ngầm · P1 · Figma M05, D02, D06 MỚI v0.9

Mô tả	Desktop shall tách token và chi phí của phiên phụ (FR-DATA-001) theo nguồn và model. Mobile Analytics và desktop Overview hiển thị dòng “Hidden cost” gồm tỷ lệ chi phí ngầm và model phụ đóng góp nhiều nhất. Tổng token và chi phí vẫn bao gồm phiên phụ.
Quy tắc dữ liệu	Hidden cost share = chi phí phiên phụ ÷ tổng chi phí × 100; thiếu giá → hiển thị theo token và ghi “thiếu giá”
Nghiệm thu	Given một phiên Codex có `thread_source = guardian_review`, model `codex-auto-review`, then token của phiên đó xuất hiện ở dòng Hidden cost của Codex và vẫn được tính vào tổng. Given tỷ lệ chi phí ngầm > 30%, then chỉ số có nhãn Review.

FR-COST-001 — Ước tính và giải thích chi phí · P0 · Figma O03

Mô tả	Desktop shall tính chi phí ước tính USD theo nguồn, model, loại token (input không cache, cached, cache write, output) và PricingVersion có hiệu lực. Bảng chi tiết chi phí hiển thị từng dòng Input (phần không cache), Cached input, Cache write, Output dưới dạng số token × đơn giá, tổng, ghi chú “ước tính theo giá API” và nút xem bảng giá. Claude Code: cache write tính theo loại 5 phút hoặc 1 giờ nếu bảng giá có hai mức. SỬA v0.9

Quy tắc dữ liệu	Giá ≥ 0; thiếu giá → PRICING_NOT_FOUND, cost của model đó là unavailable. Khi Claude Code ghi sẵn `costUSD`, desktop chỉ dùng để đối chiếu, không thay cho công thức §10.1.
Nghiệm thu	Given 100K input không cache, 20K cached, 30K output với giá 1.75 / 0.175 / 14.00 USD mỗi triệu token, then các dòng là 0.1750, 0.0035, 0.4200 và tổng 0.5985 USD. Given thêm bảng giá mới, then chi phí lịch sử không đổi.

FR-COST-002 — Bảng giá model · P1 · Figma M14

Mô tả	App shall hiển thị bảng giá đang dùng theo từng nguồn (model, giá input, cached, cache write, output mỗi triệu token; nguồn không có cache write hiển thị "—"), độ mới của bảng giá và ghi chú nguồn giá.
Quy tắc dữ liệu	Chỉ đọc; bảng giá do nhóm cập nhật
Nghiệm thu	Given bảng giá cũ hơn 30 ngày, then chỉ báo độ mới chuyển sang cảnh báo.

4.5 Insights, ngân sách và cảnh báo

FR-RECO-001 — Suggestions · P0 · Figma M07 SỬA v0.9

Mô tả	Skill ai-usage-optimizer shall chạy trên mobile mỗi ngày một lần (khi mở app nếu lần chạy trước đã quá 24 giờ), gọi LLM do người dùng tự chọn và tự cấu hình API key (FR-AIKEY-001), với đầu vào là DailySummary 30 ngày đã ẩn danh tên project và EfficiencyReport (chỉ số, nhãn Good/Review, kết luận so sánh và mức chắc chắn do desktop tính). LLM chỉ giải thích nguyên nhân và đưa hành động; LLM không tự tính số, không được hỏi "setup nào tốt hơn" và không được đổi kết luận so sánh của desktop. Mỗi gợi ý phải bám vào ít nhất một chỉ số đang Review hoặc một kết luận so sánh không phải "Chưa đủ dữ liệu". Mọi gợi ý (tiêu đề, phát hiện, bằng chứng, hành động, mức tiết kiệm) do LLM sinh ra từ dữ liệu thực tế của người dùng; app không có danh sách gợi ý cố định hay luật if-then viết sẵn, các gợi ý mẫu trên Figma M07 chỉ minh họa. App chỉ quy định khuôn JSON đầu ra để kiểm tra và hiển thị. Kết quả ghi lên Firestore. Tab Insights hiển thị tổng tiết kiệm tiềm năng mỗi tháng, số gợi ý, từng gợi ý (tiêu đề, bằng chứng ngắn, mức tiết kiệm) và phần "How recommendations work". Chạm một gợi ý mở M08 Insight Detail (bằng chứng, hành động, confidence). Trạng thái theo Figma: Analyzing, Insufficient data, No significant issues, Analysis failed, Insights stale, AI not set up. Chưa cấu hình API key thì Insights hiển thị nút mở M15 AI Suggestions.
Quy tắc dữ liệu	Cần ≥ 3 ngày có dữ liệu hoặc ≥ 10 bản ghi DailySummary; thiếu → INSUFFICIENT_DATA. Chưa có key → AI_KEY_MISSING; key sai hoặc hết quota → AI_PROVIDER_ERROR. Khuyến nghị (không bắt buộc): chọn model gợi ý khác họ với model được đánh giá nhiều nhất, vì model có xu hướng ưu ái văn của chính mình (Panickssery 2024). Khi LLM trả kết quả không hợp lệ, gọi lại tối đa 3 lần rồi lấy kết quả hợp lệ đầu tiên.
Nghiệm thu	Given đủ dữ liệu và key hợp lệ, then mỗi gợi ý dẫn metric, kỳ và giá trị; app đối chiếu số liệu trích dẫn với DailySummary và EfficiencyReport và loại gợi ý có số không khớp; tổng tiết kiệm tiềm năng bằng tổng mức tiết kiệm của các gợi ý hiển thị. Given gợi ý khẳng định một setup tốt hơn trong khi EfficiencyReport ghi "Chưa đủ dữ liệu", then app loại gợi ý đó. Given key lỗi, then gợi ý cũ vẫn hiển thị kèm thông báo lỗi.

FR-AIKEY-001 — Cấu hình LLM cho gợi ý · P0 · Figma M09, M15

Mô tả	Mobile Settings shall có dòng "AI suggestions" hiển thị provider · model đang dùng, mở màn M15. M15 cho chọn provider (OpenAI, Anthropic, Google Gemini), nhập tên model tự do (bất kỳ model nào provider hỗ trợ), nhập/sửa API key, xem trạng thái kết nối và bấm Test connection. Key lưu trong Android Keystore (flutter_secure_storage) trên điện thoại, không bao giờ lên Firestore hay desktop. Desktop không có cấu hình AI.
Quy tắc dữ liệu	`ai_provider` ∈ {openai, anthropic, gemini}; `ai_model` là chuỗi không rỗng; key sai → AI_PROVIDER_ERROR
Nghiệm thu	Given key hợp lệ, when bấm Test connection, then hiện "Connected" trong ≤ 10 giây. Given đã lưu key, then không tìm thấy key trong Firestore, file log hay file export. Given provider từ chối key, then M15 hiện trạng thái Invalid API key và gợi ý cũ vẫn hiển thị.

FR-BUDG-001 — Ngân sách · P1 · Figma M11

Mô tả	Người dùng shall đặt hạn mức tháng. Màn Budget hiển thị chi phí tháng hiện tại trên hạn mức, % đã dùng, số ngày còn lại trong tháng và ba mức cảnh báo 70%, 90%, 100%; mỗi mức hiển thị ngày đã chạm hoặc công tắc bật/tắt push.
Quy tắc dữ liệu	`monthly_budget_usd`: 0.01–1,000,000; sai → BUDGET_INVALID. Mức cảnh báo cố định {70, 90, 100}
Nghiệm thu	Given hạn mức 50 USD, when chi phí tăng từ 44 lên 46 USD, then tạo đúng một BudgetAlert 90% trong tháng. Given mức 70% đã chạm, then dòng 70% hiển thị "Reached <ngày>".

FR-NOTI-001 — Cảnh báo ngân sách · P1 · Figma O02, D08

Mô tả	Desktop shall kiểm tra ngân sách sau mỗi lần cập nhật DailySummary; khi chạm mức có bật thông báo, desktop tạo BudgetAlert trên Firestore và hiện thông báo trên máy tính (nếu bật Usage notifications). Mobile lắng nghe BudgetAlert và hiện thông báo cục bộ trên Android (flutter_local_notifications), không cần server. Màn Budget alert hiển thị % đã dùng, chi phí trên hạn mức, số tiền còn lại, model đóng góp nhiều nhất, nút View usage và Dismiss.
Quy tắc dữ liệu	Người dùng từ chối quyền thông báo thì chỉ hiển thị trong app
Nghiệm thu	Given app mobile đang mở hoặc chạy nền, when có BudgetAlert mới, then thông báo hiện trong ≤ 1 phút. Given app đã bị tắt, then thông báo hiện ở lần mở app kế tiếp (giới hạn do không có push server, xem R-06).

4.6 Cài đặt, quyền riêng tư và dữ liệu

FR-SETT-001 — Cài đặt mobile · P0 · Figma M09, M13

Mô tả	Settings shall gồm: Desktop collector, AI suggestions (FR-AIKEY-001), Language, Budget & alerts, Token numbers, Model pricing, Sync interval, Privacy, Account. Account hiển thị hồ sơ Google, Cloud sync (chỉ trạng thái, luôn bật vì mobile đọc dữ liệu từ Firestore), Export, Connected devices, quản lý tài khoản Google, phiên bản app và Sign out.

Quy tắc dữ liệu	`language` ∈ {system, vi, en}; `token_format` ∈ {compact, full}; `sync_interval_minutes` như FR-SYNC-002
Nghiệm thu	Given chọn Token numbers = Full, then 6.83M hiển thị thành 6,830,736 trên mọi màn hình.

FR-PRIV-001 — Quyền riêng tư và xóa dữ liệu · P0 · Figma M12 SỬA v0.9

Mô tả	Màn Privacy shall liệt kê dữ liệu thu thập (token, model và nguồn, thời gian và latency, trạng thái đúng/sai của lệnh test/build), dữ liệu không thu (prompt, response, lệnh terminal, kết quả lệnh: ở lại trên máy), dữ liệu tùy chọn (Diagnostics: log crash và sync, có công tắc) và nút "Delete all usage data". M13 Account shall có dòng "Delete account" để xóa tài khoản sau khi đăng nhập lại Google (Figma có trạng thái Deleting account, Delete failed, Delete partial).
Quy tắc dữ liệu	Xóa yêu cầu gõ `DELETE`; sai → DELETE_CONFIRMATION_INVALID. Diagnostics chỉ chứa metadata
Nghiệm thu	Given xác nhận hợp lệ, when xóa, then UsageEvent, TaskOutcome, DailySummary, EfficiencyReport, Recommendation, BudgetAlert của UID không còn truy cập được ngay và bị xóa vật lý trong ≤ 30 ngày. Given tắt Diagnostics, then không có log crash/sync nào được gửi đi.

FR-EXP-001 — Xuất dữ liệu · P1 · Figma O01, D08

Mô tả	Mobile shall xuất DailySummary theo tháng ra CSV hoặc JSON, hiển thị trước số bản ghi, tổng token, chi phí, số ngày và tỉ trọng nguồn; file tạo trên thiết bị. Desktop cho xuất UsageEvent và TaskOutcome chi tiết từ SQLite và xóa dữ liệu cục bộ.
Quy tắc dữ liệu	`format` ∈ {csv, json}; file chỉ chứa metadata usage
Nghiệm thu	Given tháng 11 có 312 bản ghi DailySummary, when tải CSV, then file có đúng 312 dòng dữ liệu và tổng token khớp màn Export.

FR-DSET-001 — Cài đặt desktop · P1 · Figma D08, D09

Mô tả	Desktop Settings shall có: Launch at startup, Background collection, Automatic updates, Usage notifications, đường dẫn lưu dữ liệu cục bộ (Open folder), phiên bản và Check updates, thời gian lưu dữ liệu cục bộ (Change retention), Export data, Clear local data, Open diagnostics. Khi collector dừng, Overview hiển thị trạng thái offline, hoạt động cuối, nguyên nhân và nút Restart collector.
Quy tắc dữ liệu	`local_retention_days` ∈ {7, 30, 90}, mặc định 30. EfficiencyReport cần 30 ngày dữ liệu; chọn 7 ngày thì báo cáo chỉ tính trên 7 ngày và hiển thị cảnh báo. SỬA v0.9
Nghiệm thu	Given retention 30 ngày, then event cục bộ cũ hơn 30 ngày bị xóa khỏi máy, dữ liệu đã sync lên tài khoản không bị ảnh hưởng. Given restart collector, then dữ liệu đã lưu không bị mất.

5. Trạng thái, phân quyền và lỗi

5.1 State machine

Trạng thái kết nối và trạng thái từng lần đồng bộ được tách thành hai máy riêng; COMPANION_OFFLINE là kết quả của một SyncRequest, không phải trạng thái của Connection.

Connection

Từ	Sự kiện	Đến	Ghi chú
(khởi tạo)	create_code	Pairing	Mobile tạo mã trong `users/{uid}/pairing`
Pairing	pair_verified	Connected	Desktop cùng tài khoản nhập đúng mã
Pairing	code_expired / cancel / reject	Disconnected	Mã bị hủy
Connected	disconnect	Revoked	Desktop ngừng ghi lên Firestore, giữ dữ liệu
Connected	source_error	Degraded	SOURCE_NOT_FOUND, SOURCE_PERMISSION_DENIED, SOURCE_FORMAT_UNSUPPORTED
Degraded	sync_succeeded	Connected	Lỗi nguồn đã được khắc phục
Degraded	disconnect	Revoked	

SyncRequest

Từ	Sự kiện	Đến
(khởi tạo)	mobile ghi yêu cầu	Pending
Pending	desktop nhận qua listener	Running
Pending	quá 30 giây không được nhận	Failed (COMPANION_OFFLINE)
Running	cập nhật DailySummary và EfficiencyReport xong	Done
Running	lỗi sau 3 lần thử	Failed (mã lỗi cụ thể)

TaskOutcome MỚI v0.9

Từ	Sự kiện	Đến
(khởi tạo)	turn đầu tiên của task	Open
Open	turn mới trong ≤ 2 phút sau turn trước	Open (gộp vào task, tăng số lần làm lại)
Open	quá 2 phút không có turn mới, hoặc session kết thúc	Closed (gán outcome_state theo FR-ANLY-003 mục B)
Closed	log mới thay đổi tín hiệu của task (đọc lại)	Closed (tính lại outcome_state, idempotent)

Revoked, Done, Failed là trạng thái cuối. Ghép nối lại sau Revoked tạo Connection mới. Transition không có trong bảng bị từ chối với STATE_INVALID, không đổi trạng thái, không tạo side effect. Request lặp cùng idempotency key trả trạng thái hiện tại.

5.2 CRUD matrix

Entity	Nơi lưu	Create	Read	Update	Delete
User	Firestore	FR-AUTH-001	FR-SETT-001	FR-SETT-001	FR-PRIV-001
Connection	Firestore	FR-CONN-001	FR-CONN-002	FR-CONN-002, FR-SRC-001	FR-CONN-002
SyncRequest	Firestore	FR-SYNC-001	FR-SYNC-001	FR-SYNC-001	Desktop xóa sau 7 ngày
UsageEvent	SQLite desktop	FR-DATA-001	FR-ACT-001, FR-EXP-001	FR-DATA-001	FR-DSET-001
TaskOutcome MỚI	SQLite desktop	FR-DATA-001	FR-ANLY-003, FR-EXP-001	FR-ANLY-003	FR-DSET-001, FR-PRIV-001
DailySummary (một document mỗi ngày)	Firestore `daily/{date}`; bản nháp ở SQLite `daily_local`	FR-DATA-002	FR-DASH-001, FR-ANLY-001/002/004	FR-DATA-002	FR-PRIV-001
SourceFile (SQLite) MỚI v0.10	`path_hash`, `provider`, `size`, `mtime`, `read_offset`, `completed`, `parser_version`, `last_ok_at`				
SyncQueueItem (SQLite) MỚI v0.10	`id`, `doc_path`, `payload_json`, `attempts`, `next_retry_at`, `created_at`				
EfficiencyReport MỚI	Firestore	FR-DATA-002	FR-ANLY-003, FR-RECO-001	FR-DATA-002 (ghi đè)	FR-PRIV-001

Recommendation	Firestore	FR-RECO-001	FR-RECO-001	FR-RECO-001	FR-PRIV-001
Budget	Firestore	FR-BUDG-001	FR-BUDG-001	FR-BUDG-001	FR-PRIV-001
BudgetAlert	Firestore	FR-NOTI-001	FR-NOTI-001	FR-NOTI-001 (dismiss)	FR-PRIV-001
AiConfig	Android Keystore trên điện thoại	FR-AIKEY-001	FR-AIKEY-001	FR-AIKEY-001	FR-AIKEY-001
PricingVersion	Đóng gói trong app + Firestore `pricing/` (chỉ đọc)	Nhóm cập nhật	FR-COST-001/002	Chỉ thêm version	Không xóa

5.3 Permission matrix

Vai trò	Quyền	Phạm vi dữ liệu
Mobile (đã đăng nhập)	Đọc mọi dữ liệu của mình; ghi pairing, sync_requests, settings, budget, recommendations, dismiss alert; xóa dữ liệu	`users/{uid}/**` với `uid == request.auth.uid`
Desktop (đăng nhập cùng tài khoản)	Ghi connection, daily, efficiency, budget_alerts; cập nhật sync_requests SỬA v0.9	Như trên; bị chặn khi Connection = Revoked
Optimizer skill	Chạy trong app mobile, chỉ gửi DailySummary đã ẩn danh và EfficiencyReport cho LLM	Không truy cập Firestore trực tiếp
Chưa đăng nhập	Đọc `pricing/`	Không có dữ liệu người dùng

Quyền được thực thi bằng Firestore Security Rules; truy cập dữ liệu của UID khác bị từ chối (permission-denied), app hiển thị RESOURCE_NOT_FOUND.

5.4 Danh mục lỗi

Mã lỗi	Khi xảy ra	Cách xử lý (màn Figma)
AUTH_INVALID	Phiên Google/Firebase sai hoặc hết hạn	Đăng nhập lại (M01 Session expired)
ACCOUNT_MISMATCH	Desktop đăng nhập khác tài khoản với mobile	Đăng nhập lại đúng tài khoản
PAIRING_INVALID	Mã ghép nối sai	Nhập lại (M02 Wrong code)
PAIRING_EXPIRED	Mã quá 10 phút	Tạo mã mới (M02 Code expired)
PAIRING_USED	Mã đã được dùng	Tạo mã mới (M02 Code already used)
COMPANION_OFFLINE	Desktop không nhận yêu cầu sync trong 30 giây	Mở collector rồi thử lại (S04, D09)
SOURCE_NOT_FOUND	Không tìm thấy log của nguồn đang bật	Cài/chạy tool tương ứng (D05 Not found)
SOURCE_PERMISSION_DENIED	Hệ điều hành chặn quyền đọc log	Cấp lại quyền (D10)
SOURCE_FORMAT_UNSUPPORTED	Định dạng log không khớp parser hoặc sai phép kiểm tra ở §10.4	Cập nhật collector
SOURCE_UNAVAILABLE	Đọc nguồn lỗi sau 3 lần thử	Hiển thị dữ liệu cũ kèm nhãn stale
PROVIDER_INVALID	Giá trị provider không thuộc ba nguồn	Không ghi dữ liệu
TRIGGER_INVALID	Trigger sync không hỗ trợ	Gửi giá trị hợp lệ
METRIC_INVALID	Metric sai kiểu hoặc sai miền	Không ghi dữ liệu, ghi log collector
PERIOD_INVALID	Bộ lọc thời gian không thuộc day/week/month/total	Chọn lại
PRICING_NOT_FOUND	Không có giá cho model	Vẫn hiển thị token, cost của model đó unavailable
INSUFFICIENT_DATA	Chưa đủ dữ liệu cho gợi ý	Tiếp tục dùng và đồng bộ
INSUFFICIENT_SAMPLE MỚI	Setup chưa qua bước 2 của FR-ANLY-003	Hiển thị "Chưa đủ dữ liệu · n/20", không xếp hạng
AI_KEY_MISSING	Chưa cấu hình provider/API key cho gợi ý	Mở M15 AI Suggestions
AI_PROVIDER_ERROR	API key sai, hết quota hoặc provider lỗi	Giữ gợi ý cũ, báo kiểm tra key
BUDGET_INVALID	Hạn mức ngoài miền	Sửa giá trị
DELETE_CONFIRMATION_INVALID	Xác nhận khác DELETE	Không xóa
STATE_INVALID	Chuyển trạng thái không hợp lệ	Giữ nguyên trạng thái
RESOURCE_NOT_FOUND	Record không tồn tại hoặc bị Rules từ chối	Kiểm tra tài khoản/tài nguyên

6. Yêu cầu dữ liệu

6.1 Quan hệ giữa các entity

Entity	Quan hệ
User	có 0..n Connection (tối đa 1 đang Connected), 0..1 Budget, 0..n DailySummary, Recommendation, BudgetAlert, SyncRequest; 0..1 EfficiencyReport hiện hành
Connection	một máy tính; máy đó giữ 0..n UsageEvent và TaskOutcome trong SQLite
UsageEvent	thuộc 1 session và 1 task; được tổng hợp vào 1 DailySummary theo (ngày, nguồn, model, project)
TaskOutcome MỚI	gồm 1..n turn của cùng session; được tổng hợp vào DailySummary (đếm theo trạng thái) và EfficiencyReport (theo setup, nhóm việc)
DailySummary	tham chiếu 1 PricingVersion
Budget	có 0..n BudgetAlert

Cấu trúc Firestore: `users/{uid}` (hồ sơ + cài đặt) với các subcollection `connections`, `pairing`, `sync_requests`, `daily` SỬA v0.10, `efficiency` MỚI, `recommendations`, `budget`, `budget_alerts`; collection `pricing` dùng chung, chỉ đọc.

6.2 Data dictionary

Trường có dấu `?` là tùy chọn: nguồn không cung cấp thì lưu `null`, không lưu 0.

Entity	Trường
User	`user_id`, `email`, `display_name`, `timezone` (lấy từ thiết bị), `language`, `token_format`, `sync_interval_minutes`, `diagnostics_enabled`, `ai_provider?`, `ai_model?`, `ai_status?`, `created_at`
Connection	`connection_id`, `device_name`, `platform`, `app_version`, `sources[] {provider, enabled, status, parser_version, last_event_at}`, `state`, `last_error?`, `last_seen_at`, `last_sync_at?`, `queued_events`, `created_at`
SyncRequest	`request_id`, `trigger`, `state`, `error_code?`, `created_at`, `finished_at?`
UsageEvent (SQLite)	`provider`, `source_event_id`, `session_id`, `turn_id?`, `task_id?`, `model`, `effort?`, `project_key?`, `occurred_at`, `input_tokens`, `cached_tokens`, `cache_write_tokens`, `cache_write_1h_tokens?`, `output_tokens`, `thinking_tokens?`, `duration_ms?`, `status` (ok/warning/error), `is_side_session`, `parent_session_id?`, `estimated_cost_usd?`, `pricing_version?`, `parser_version`, `synced` SỬA v0.9
TaskOutcome (SQLite) MỚI	`task_id`, `provider`, `session_id`, `model`, `effort?`, `project_key?`, `task_group` (small/medium/large), `started_at`, `ended_at`, `turns`, `requests`, `redo_turns`, `commands_total?`, `commands_failed?`, `max_consecutive_failures?`, `test_runs?`, `last_test_passed?`, `files_changed?`, `turn_error`, `aborted`, `outcome_state` (verified_success / verified_failure / likely_success / likely_failure / undetermined), `cost_usd_micro?`, `total_tokens`, `context_growth?`, `state` (open/closed)
DailySummary (Firestore `daily/{date}`) SỬA v0.10	`date`, `totals` {...}, `by_key` { `provider|model|project_key` → {...}}, `tasks_by_state`, `pricing_version`, `schema_version` = 2, `updated_at`. Mỗi breakdown gồm: `chats`, `requests`, `input_tokens`, `cached_tokens`, `cache_write_tokens`, `output_tokens`, `thinking_tokens?`, `error_requests`, `side_requests`, `side_tokens`, `side_cost_usd?`, `context_growth_sum`, `context_growth_count`, `bloated_chats`, `tasks_by_state {verified_success, verified_failure, likely_success, likely_failure, undetermined}`, `duration_sum_ms?`, `duration_count?`, `estimated_cost_usd?`, `pricing_version`, `schema_version`, `updated_at` SỬA v0.9
EfficiencyReport MỚI	id cố định `current`; `period_start`, `period_end`, `generated_at`, `schema_version`, `process_metrics[] {metric, provider?, value?, label}`, `setups[] {provider, model, effort?, task_group, n_tasks, n_sessions, sr?, sr_ci_low?, sr_ci_high?, sr_alt?, cpst?, cpst_ci_low?, cpst_ci_high?, cost_p50?, cost_p90?, weekly_sr[], redo_rate?, mde?, stability_flag, verdict, confidence?, compared_to?, cross_tool}`, `undetermined_tasks`
Recommendation	`recommendation_id`, `title`, `evidence{metric, period, value}`, `estimated_saving_usd_month?`, `action`, `confidence`, `ai_provider`, `ai_model`, `generated_at`
Budget	`monthly_budget_usd`, `push_enabled{70, 90, 100}`, `updated_at`
BudgetAlert	`month` (YYYY-MM), `level` ∈ {70, 90, 100}, `cost_at_alert_usd`, `top_model`, `dismissed`, `created_at`; id document = `{month}_{level}` để không trùng
AiConfig (Android Keystore trên điện thoại)	`ai_provider`, `ai_model`, `api_key`
PricingVersion	`pricing_version`, `effective_from`, `provider`, `model`, `input_per_mtok`, `cached_input_per_mtok`, `cache_write_per_mtok?`, `cache_write_1h_per_mtok?`, `output_per_mtok`, `source_note`

6.3 Quy tắc dữ liệu

- Token, request, error là số nguyên ≥ 0; `cached_tokens + cache_write_tokens ≤ input_tokens`; `thinking_tokens ≤ output_tokens` (chuẩn hóa theo §10.4).
- Cost lưu dạng micro-USD số nguyên, không dùng số thực dấu phẩy động.
- Thời điểm lưu UTC; ngày và tháng tính theo `User.timezone`.
- `project_key` là mã băm của đường dẫn project; tên hiển thị chỉ lưu trên máy và đồng bộ lên `users/{uid}` để mobile hiển thị; không gửi cho LLM gợi ý.
- Thời gian phản hồi trung bình tính từ `duration_sum_ms / duration_count`, không lấy trung bình của trung bình.

- UsageEvent và TaskOutcome chỉ nằm trên máy; Firestore chỉ chứa dữ liệu tổng hợp, để ít lượt ghi (vừa hạn mức gói Spark) và ít dữ liệu nhạy cảm trên cloud. SỬA v0.9
- TaskOutcome không chứa tên lệnh, đường dẫn file hay nội dung; chỉ chứa số đếm và cờ đúng/sai. MỚI v0.9
- Mỗi lần sync ghi tối đa document ngày hiện tại (và ngày bị tính lại) cùng `efficiency/current`; khoảng 2 lượt ghi. Ước tính < 200 lượt ghi/ngày/người với chu kỳ 15 phút. MỚI v0.10
- Phân vị (P50, P90) và khoảng tin cậy chỉ tính trên desktop từ dữ liệu từng task; không tính lại trên mobile từ DailySummary. MỚI v0.9

7. Giao diện ngoài

7.1 Giao diện người dùng

Figma file "µToken — Mobile UI + Desktop Companion" (trang Final UI · Light/Dark và Desktop Companion) là chuẩn giao diện; SRS chỉ liệt kê màn hình và FR tương ứng. Nền tối, phẳng, font Geist, khung mobile 393 × 852; mọi màn hình dữ liệu có trạng thái loading, empty, error, offline, stale.

Mobile — bottom navigation: Tokens · Analytics · Insights · Settings.

Màn hình	Nội dung	FR
M01 Welcome	Giới thiệu, Continue with Google, View demo	FR-AUTH-001, FR-DEMO-001
M02 Connect desktop · M03 Install guide	Mã ghép nối, đếm ngược, hướng dẫn cài desktop	FR-CONN-001
M04 Tokens · M04B Usage details · M06 Daily usage	Tổng quan token/chi phí, nguồn, xu hướng, top model, heatmap, theo ngày/project	FR-DASH-001, FR-ANLY-001
M05 Analytics	Token mix, bảng model, chi phí 7 ngày, dòng Efficiency, dòng Hidden cost SỬA v0.9	FR-ANLY-002, FR-ANLY-004
M05B Efficiency CẦN SỬA FIGMA	Outcome (SR chính/phụ ± khoảng tin cậy, CPST, P50/P90 chi phí mỗi task, tỷ lệ làm lại, số task chưa xác định), Process (chỉ số có nhãn Good/Review, gồm chi phí ngầm), lối vào Compare setups, liên kết sang Insights	FR-ANLY-003
M05C Compare setups CẦN SỬA FIGMA	Chọn nguồn và nhóm việc; bảng setup với SR ± khoảng tin cậy, CPST, cờ ổn định, chip kết luận, mức chắc chắn; tiến độ "n/20" cho setup chưa đủ dữ liệu; Best pick chỉ khi có kết luận đủ mạnh. Thay bảng xếp hạng theo Efficiency Index	FR-ANLY-003
M07 Insights (Suggestions)	Tiết kiệm tiềm năng, danh sách gợi ý	FR-RECO-001
M08 Insight Detail	Chi tiết một gợi ý: bằng chứng, hành động, confidence	FR-RECO-001
M09 Settings · M13 Account	Cài đặt chung, tài khoản, đăng xuất	FR-SETT-001
M15 AI Suggestions	Chọn provider, model, API key, trạng thái kết nối, Test connection	FR-AIKEY-001
M10 Desktop	Trạng thái collector, token theo nguồn, Sync now, Disconnect	FR-CONN-002, FR-SYNC-001
M11 Budget · O02 Budget alert	Hạn mức, cảnh báo 70/90/100%	FR-BUDG-001, FR-NOTI-001
M12 Privacy	Dữ liệu thu/không thu, Diagnostics, xóa dữ liệu	FR-PRIV-001
M14 Model pricing · O03 Cost breakdown	Bảng giá, giải thích chi phí	FR-COST-001, FR-COST-002
O01 Export	Xuất CSV/JSON	FR-EXP-001
S01–S04	Chưa ghép nối, chờ usage đầu tiên, đang sync, sync lỗi	FR-DASH-001, FR-SYNC-001

Desktop — thanh bên: Overview · Sources · Sync · Settings.

Màn hình	Nội dung	FR
D01 First run	Đăng nhập Google, cho phép đọc log, ghép nối	FR-AUTH-001, FR-CONN-001
D02 Overview · D04 Activity	Tổng quan (gồm chi phí ngầm), luồng event có lọc và chi tiết	FR-ACT-001, FR-ANLY-004
D03 Pairing · D13+ trạng thái ghép nối	Nhập mã, chờ, xác minh, hết hạn, bị từ chối, revoked, cần cập nhật	FR-CONN-001, FR-SYNC-003
D05 Sources · D06 Source detail · D10 Permission required (macOS) · D10L (Linux)	Trạng thái nguồn (gồm "No usage data"), phạm vi thu thập, quyền đọc log	FR-SRC-001
D07 Sync · D12 Sync failed	Thiết bị đã ghép nối, lịch sử sync, hàng đợi	FR-CONN-002, FR-SYNC-002
D08 Settings · D09 Collector offline · D11 Empty usage	Cài đặt collector, lưu trữ, chẩn đoán	FR-DSET-001

7.2 Giao diện phần cứng

Smartphone chạy mobile app; máy tính chạy companion. Camera chỉ dùng tùy chọn để quét QR ghép nối; không dùng GPS, microphone, Bluetooth.

7.3 Giao diện phần mềm

- Firebase Authentication (Google Sign-In) và Cloud Firestore (gói Spark). Mobile dùng SDK Flutter (offline persistence bật). Desktop dùng REST: đăng nhập Google OAuth (loopback, PKCE) → `accounts:signInWithIdp` → Firestore REST với Firebase ID token; refresh token lưu bằng DPAPI (Windows) hoặc libsecret (Linux). SỬA v0.10
- Hệ thống file của desktop, chỉ trong allowlist (Linux/macOS; Windows dùng `%USERPROFILE%` tương ứng): SỬA v0.9
  - Codex CLI: `~/.codex/sessions/**/rollout-*.jsonl`, `~/.codex/sessions/**/rollout-*.jsonl.zst` và `~/.codex/archived_sessions/*.jsonl`
  - Antigravity: `~/.gemini/antigravity/conversations/*.db`, `~/.gemini/antigravity-ide/conversations/*.db` và `~/.gemini/antigravity/conversation_summaries.db` (SQLite, mở chế độ chỉ đọc)
  - Claude Code: `~/.claude/projects/**/*.jsonl`
  - Không được mở: `~/.codex/auth.json`, `~/.claude/.credentials.json`, mọi file trong `~/.gemini` ngoài danh sách trên, các file cấu hình và bất kỳ file nào ngoài danh sách trên
- SQLite cục bộ trên desktop: `source_files`, `sessions`, `usage_events`, `task_outcomes`, `daily_local`, `sync_queue`, `pricing`. SỬA v0.10

- Thư viện desktop: Avalonia UI, CommunityToolkit.Mvvm, Microsoft.Data.Sqlite, Dapper, ZstdSharp. SỬA v0.10
- Android Keystore (flutter_secure_storage) trên điện thoại cho API key LLM.
- API của LLM do người dùng chọn (OpenAI, Anthropic, Google Gemini) cho gợi ý.
- flutter_local_notifications cho thông báo trên Android; thông báo hệ điều hành trên desktop (thư viện tùy ngôn ngữ desktop). SỬA v0.9
- fl_chart cho biểu đồ trên mobile.

7.4 Giao tiếp

Desktop và mobile nói chuyện với nhau qua Firestore (HTTPS/TLS), không kết nối trực tiếp. Dữ liệu được mã hóa khi truyền và khi lưu theo mặc định của Firebase; không mã hóa đầu cuối (OQ-07). Chỉ dữ liệu tổng hợp lên cloud; không upload prompt, response, transcript, lệnh terminal, source code, credential hay API key. Mobile gọi API LLM qua HTTPS, chỉ gửi DailySummary đã ẩn danh và EfficiencyReport.

8. Ma trận truy vết

Chưa có PRD nên truy vết trực tiếp từ yêu cầu stakeholder. Mục "Chờ PoC" nghĩa là yêu cầu đã viết nhưng chưa chứng minh được khả thi.

Source ID	Yêu cầu stakeholder	SRS ID	Trạng thái
STK-001	Mobile, desktop companion và Firebase	FR-AUTH-001, FR-CONN-001, FR-CONN-002, §3.4	Covered
STK-002	Hỗ trợ Antigravity, Codex CLI, Claude Code	FR-SRC-001, FR-DATA-001, FR-SYNC-003, FR-ACT-001	Codex: đã xác nhận. Claude Code: định dạng đã xác nhận, chờ kiểm tra CLI (R-01). Antigravity: chờ OQ-10 SỬA v0.9
STK-003	Dashboard usage và chi phí	FR-DASH-001, FR-ANLY-001, FR-ANLY-002, FR-COST-001, FR-COST-002	Covered
STK-004	Đánh giá hiệu suất sử dụng, không chỉ khối lượng	FR-ANLY-003, FR-ANLY-004	Đề xuất v2, chờ nhóm duyệt (OQ-03); Figma M05B, M05C cần sửa SỬA v0.9
STK-005	Skill đưa khuyến nghị	FR-RECO-001	Covered
STK-006	Ngân sách và cảnh báo	FR-BUDG-001, FR-NOTI-001	Covered
STK-007	Collector chạy trên desktop, không cần realtime	FR-SYNC-001, FR-SYNC-002, FR-DATA-002, FR-DSET-001	Covered
STK-008	Người dùng kiểm soát dữ liệu và quyền riêng tư	FR-PRIV-001, FR-EXP-001, FR-SETT-001	Covered
STK-009	Giao diện theo Figma đã được GV duyệt	§7.1, FR-DEMO-001	Covered, trừ M05B, M05C cần sửa

9. Nghiệm thu và kiểm soát thay đổi

9.1 Điều kiện baseline

SRS được baseline khi đủ các điều kiện:

- PoC đọc log Codex và Antigravity (§10.4, 2026-11-02; bổ sung 2026-11-05).
- Nhóm xác nhận định dạng log Claude Code CLI trên máy thật (định dạng đã kiểm tra trên phiên Claude Agent SDK ngày 2026-11-05).
- Nhóm duyệt FR-ANLY-003 bản đề xuất v2 (OQ-03) và cập nhật Figma M05B, M05C. MỚI v0.9
- Giảng viên duyệt phạm vi ba nguồn, đọc dữ liệu cục bộ (gồm đọc tên lệnh để nhận diện test, OQ-11) và thiết kế Figma.
- Chốt nền tảng: Android 9+; desktop .NET 10 + Avalonia, Windows trước, Linux (Ubuntu) sau (đã chốt v0.10).
- Bổ sung mục AI suggestions vào Figma (M09 + màn M15, cả Dark, Light, Prototype) và sửa chữ "End-to-end encryption" (đã làm 2026-11-02).

9.2 Định nghĩa nghiệm thu

- FR được chấp nhận khi tiêu chí nghiệm thu tương ứng pass trên staging.
- Mọi màn hình dữ liệu có trạng thái loading, empty, error, stale như thiết kế Figma.
- Không còn lỗi Blocker: truy cập chéo UID, upload prompt/credential/transcript/lệnh, sai token hoặc cost, đếm trùng phản hồi Claude Code, mất dữ liệu, không sync được dữ liệu hợp lệ của bất kỳ nguồn nào, hiển thị kết luận so sánh khi chưa đủ dữ liệu.

9.3 Môi trường nghiệm thu

Firebase staging, máy tính có usage thật của cả ba nguồn, PricingVersion đã pin, release build của mobile và desktop. Bộ dữ liệu kiểm thử cho FR-ANLY-003 gồm ít nhất 30–50 task được người gán nhãn thành công/thất bại để kiểm chứng luật suy ra trạng thái. MỚI v0.9

9.4 Kiểm soát thay đổi

Mọi thay đổi ghi rõ requirement ID bị ảnh hưởng, đánh giá phạm vi và sửa trực tiếp tài liệu này; không tạo bản SRS song song. ID đã cấp không được dùng lại cho ý nghĩa khác.

CR	Thay đổi	Trạng thái
CR-009	Lưu trữ lai (SQLite + một document Firestore mỗi ngày), hàng đợi SQLite, desktop .NET 10 + Avalonia qua REST, kết luận "Chưa thấy khác biệt". Ảnh hưởng: FR-SYNC-001/002, FR-DATA-002, FR-ANLY-003, §3, §5, §6, §7.3, R-10, OQ-09, OQ-13	Applied in v0.10

CR-008	Đề xuất v2 cho FR-ANLY-003 theo báo cáo nghiên cứu; thêm FR-ANLY-004, TaskOutcome, EfficiencyReport, INSUFFICIENT_SAMPLE; cập nhật PoC Claude Code, Codex, Antigravity; allowlist `.jsonl.zst` và `conversation_summaries.db`; desktop không bắt buộc Flutter. Ảnh hưởng: FR-SRC-001, FR-DATA-001/002, FR-ACT-001, FR-ANLY-003/004, FR-COST-001, FR-RECO-001, FR-PRIV-001, FR-EXP-001, FR-DSET-001, §3, §5, §6, §7, §10	Applied in v0.9 (FR-ANLY-003 chờ duyệt)
CR-007	Chốt vấn đề mở với nhóm: Firebase Spark, LLM tự cấu hình, Android, không E2E; cập nhật theo PoC log	Applied in v0.8
CR-006	Mở rộng sang Codex CLI và Claude Code theo Figma đã được GV duyệt; bỏ yêu cầu phi chức năng	Applied in v0.7
CR-005	Rà soát v0.5: state machine, data model, công thức, múi giờ, bảo mật, NFR, RTM	Applied in v0.6
CR-004	Sửa tính nhất quán của project summary, permission và Analytics	Applied in v0.5
CR-003	Bỏ quota, lịch reset, thông tin gói; thêm project attribution	Applied in v0.4
CR-002	Thêm desktop companion, chuyển nguồn sang Antigravity local usage	Applied in v0.3
CR-001	Chuyển provider MVP từ Codex sang Gemini API	Applied in v0.2

10. Phụ lục

10.1 Công thức

Sau chuẩn hóa (§10.4), `input_tokens` là toàn bộ input kể cả phần cache, `output_tokens` là toàn bộ output kể cả thinking. Vì vậy cached và thinking không được cộng thêm:

```
total_tokens = input_tokens + output_tokens
```

Chi phí tách input thành ba phần để không tính chồng:

```
cost = [ (input − cached − cache_write) × p_in + cached × p_cache + cache_write × p_write + output × p_out ] ÷ 10^6
```

Với p là giá USD trên 1 triệu token của PricingVersion có hiệu lực; model không có giá cache write thì `p_write = p_in`; Claude Code tách cache write 5 phút và 1 giờ nếu bảng giá có hai mức.

Chỉ số	Công thức	FR
Provider / model share (%)	token của nguồn hoặc model / tổng token × 100	FR-ANLY-001
Project share (%)	token của project / tổng token × 100	FR-ANLY-001
Average latency (ms)	Σ duration_sum_ms / Σ duration_count	FR-ANLY-002
Error rate (%)	error_requests / requests × 100	FR-ANLY-002
Cache hit rate (%)	cached_tokens / input_tokens × 100 (input đã chuẩn hóa)	FR-ANLY-003
Error waste rate (%)	token của request lỗi / tổng token × 100	FR-ANLY-003
Retry rate (%)	retry_requests / requests × 100	FR-ANLY-003
Thinking share (%)	thinking_tokens / output_tokens × 100	FR-ANLY-003
Tokens per request	total token / requests	FR-ANLY-003
Budget used (%)	cost tháng hiện tại / monthly_budget_usd × 100	FR-BUDG-001
Context growth (một chat)	input_tokens lượt cuối / input_tokens lượt đầu của chat (chat ≥ 2 lượt)	FR-ANLY-003
Bloated chats (%)	số chat có context growth > 3 / số chat ≥ 2 lượt × 100	FR-ANLY-003
Tokens per turn so với trung vị (%)	(token/lượt 7 ngày gần nhất / trung vị token/lượt theo ngày trong 30 ngày − 1) × 100	FR-ANLY-003
Turns per chat	requests / chats	FR-ANLY-003
Hidden cost share (%) MỚI	chi phí phiên phụ / tổng chi phí × 100	FR-ANLY-004
SR chính MỚI	verified_success / (verified_success + verified_failure)	FR-ANLY-003
SR phụ MỚI	(verified_success + likely_success) / (tổng task − undetermined)	FR-ANLY-003
CPST MỚI	tổng chi phí của setup / số task thành công (theo SR chính)	FR-ANLY-003
Redo rate MỚI	số task có redo_turns > 0 / tổng task	FR-ANLY-003
Độ đuôi chi phí MỚI	P90 / P50 chi phí mỗi task	FR-ANLY-003
Dao động SR theo tuần MỚI	max − min của SR theo từng tuần trong kỳ (tuần có ≥ 5 task)	FR-ANLY-003

Thống kê cho so sánh setup MỚI v0.9 (Miller 2024):

```
SE(SR)        = √( SR × (1 − SR) ÷ n )          n = số task đã xác định
KTC 95%       = SR ± 1,96 × SE                   (n nhỏ: dùng khoảng Wilson)
SE_chênh      = √( SE_A² + SE_B² )               (so không theo cặp)
SE theo cụm   = tính trên tổng theo phiên        (task cùng phiên không độc lập)
MDE           ≈ (1,96 + 0,84) × SE_chênh = 2,8 × SE_chênh
n mỗi setup   ≈ 7,84 × 2 × SR × (1 − SR) ÷ MDE²
```

Ví dụ với SR ≈ 80%: MDE 20 điểm cần ~63 task mỗi setup; 15 điểm ~112; 10 điểm ~251; 5 điểm ~1.004. Khoảng tin cậy của CPST dùng bootstrap theo phiên (lấy mẫu lại các phiên 1.000 lần).

Mọi tỉ lệ có mẫu số bằng 0 hiển thị "Không có dữ liệu". Retry request là request gửi lại trong ≤ 2 phút sau một request lỗi cùng phiên.

10.2 Quyết định đã chốt

- MVP hỗ trợ ba nguồn Antigravity, Codex CLI, Claude Code; tool khác và usage API thêm bằng connector sau. Figma là chuẩn giao diện.
- Mobile chỉ Android, viết bằng Flutter. Desktop không bắt buộc Flutter (v0.9). Firebase gói Spark (Auth + Firestore); mọi xử lý chạy trên desktop.
- Desktop đọc log cục bộ theo allowlist (GV đã chấp nhận); UsageEvent và TaskOutcome ở lại máy, chỉ dữ liệu tổng hợp lên Firestore.
- Gợi ý dùng LLM do người dùng tự chọn và tự cấu hình API key; cấu hình trên điện thoại (M15), key chỉ nằm trên điện thoại.
- Không mã hóa đầu cuối; dùng mã hóa mặc định của Firebase.
- Không realtime; không lưu, không upload prompt/response.
- Ngày và tháng tính theo múi giờ người dùng.

10.3 Vấn đề mở

ID	Câu hỏi	Quyết định / trạng thái	Ảnh hưởng
OQ-01	Log local có những trường nào?	Codex, Antigravity đã kiểm tra 02/11; Codex kiểm tra lại 05/11 (thêm `.zst`, phiên phụ, exit code). Claude Code: định dạng đã kiểm tra trên phiên Agent SDK 05/11, chờ kiểm tra CLI trên máy thật SỬA v0.9	FR-DATA-001, R-01
OQ-02	GV có chấp nhận đọc dữ liệu cục bộ?	Đã chốt: GV chấp nhận đọc qua desktop app, nội bộ máy tính	R-03
OQ-03	Chốt cách tính hiệu suất sử dụng token	Đã có đề xuất v2 (FR-ANLY-003): trạng thái task từ metadata, so sánh 6 bước, luật kết luận, bỏ Efficiency Index. Chờ nhóm duyệt 7 điểm liệt kê ở FR-ANLY-003 SỬA v0.9	FR-ANLY-003, STK-004
OQ-04	Recommendation dùng LLM nào, ai trả phí?	Đã chốt: người dùng tự chọn provider và tự nhập API key trên điện thoại (M15, FR-AIKEY-001)	FR-RECO-001
OQ-05	Gói Firebase?	Đã chốt: Spark (Auth + Firestore). Báo lại nếu nâng gói	§3.1, R-06
OQ-06	Nền tảng mobile?	Đã chốt: chỉ Android	§3.4
OQ-07	Mã hóa đầu cuối như Figma ghi?	Đã chốt: không làm E2E. Dữ liệu mã hóa khi truyền (TLS) và khi lưu (mặc định của Firebase); chỉ dữ liệu tổng hợp lên cloud, API key ở lại điện thoại. Figma D07 đã đổi "End-to-end encryption" thành "Encrypted sync"	D07, D08, M10
OQ-08	"Gemini" trên Figma là gì?	Đã chốt: Antigravity	FR-SRC-001
OQ-09 MỚI	Desktop viết bằng ngôn ngữ nào?	Đã chốt (v0.10): .NET 10 (C#) + Avalonia UI	§3.4, §7.3
OQ-10 MỚI	Lấy token Antigravity ở đâu khi thư mục `conversations/` rỗng?	Chờ kiểm tra: transcript theo workspace (`.gemini/antigravity/transcript.jsonl`) hoặc hook (có `modelName`, lý do kết thúc turn). Dùng hook cần cài vào cấu hình Antigravity của người dùng	FR-SRC-001, FR-DATA-001, R-08
OQ-11 MỚI	Có được đọc tên lệnh terminal (chỉ trên máy) để nhận diện test/build?	Chờ GV và nhóm chấp nhận. Không đọc thì không có trạng thái verified, chỉ còn likely/undetermined	FR-ANLY-003, FR-PRIV-001
OQ-13 MỚI v0.10	Desktop nhận `sync_requests` bằng cách nào?	Chờ spike 1 ngày: gRPC Listen với Firebase ID token; không được thì poll 60–120 giây khi Connected. Nếu poll thưa hơn, sửa tiêu chí 30 giây ở FR-SYNC-001	FR-SYNC-001, R-10
OQ-12 MỚI	Có tính mức bình thường gộp nhiều người dùng?	Đề xuất: ngoài MVP; MVP dùng lịch sử của chính người dùng	FR-ANLY-003

10.4 Kết quả PoC đọc log

Kiểm tra ngày 2026-11-02 trên máy Linux của nhóm: Codex và Antigravity đều lưu token theo từng lượt gọi model, đủ cho mọi FR. Kiểm tra bổ sung ngày 2026-11-05: 7 file Codex, thư mục Antigravity, và định dạng Claude Code trên một phiên Claude Agent SDK. Ba nguồn đếm cached và thinking theo cách khác nhau, nên parser phải quy đổi về cùng chuẩn trước khi lưu. Chỉ cấu trúc và số được đọc, không đọc nội dung hội thoại.

	Codex CLI / Codex Desktop	Antigravity	Claude Code
Nơi lưu	`~/.codex/sessions/YYYY/MM/DD/rollout-*.jsonl` (bản cũ `.jsonl.zst`)	`~/.gemini/antigravity/conversations/{id}.db` và `~/.gemini/antigravity-ide/conversations/{id}.db`	`~/.claude/projects/{project}/{session}.jsonl`
Định dạng	JSON Lines	SQLite; bảng `gen_metadata`, cột `data` là protobuf	JSON Lines
Bản ghi usage	Dòng `type = token_usage_record`, `payload.usage` (mỗi response một dòng)	Mỗi dòng `gen_metadata` là một lượt gọi model; usage ở message con 1.4	Dòng `type = assistant`, `message.usage`; **một phản hồi có thể ở nhiều dòng cùng usage** MỚI
Model, effort	`turn_context.model`, `turn_context.effort`	Trường 1.19 (id) và 1.21 (tên hiển thị)	`message.model`; effort ở dòng có trường `effort`
Input gốc	`input_tokens` (đã gồm cached)	1.4.2 = phần không cache	`input_tokens` = phần không cache
Cached	`cached_input_tokens`	1.4.5	`cache_read_input_tokens`
Cache write	`cache_write_input_tokens`	Không có (0)	`cache_creation_input_tokens`; tách `cache_creation.ephemeral_5m/1h_input_tokens` MỚI
Output gốc	`output_tokens` (đã gồm reasoning)	1.4.3 = thinking 1.4.9 + trả lời 1.4.10	`output_tokens` (đã gồm thinking)
Thinking	`reasoning_output_tokens`	1.4.9	`output_tokens_details.thinking_tokens` SỬA v0.9
Thời gian	`task_complete.duration_ms`, `time_to_first_token_ms` theo lượt	Thời điểm ở 1.9.4; chưa thấy thời lượng	`timestamp`; tổng phiên trong `cost-state`
Lỗi, kết quả MỚI	`item_completed` loại CommandExecution: `exit_code`, `status`; FileChange: `status`; `task_complete.error`; `turn_aborted`	Lý do kết thúc turn qua hook (`NO_TOOL_CALL`, `ERROR`, `USER_CANCELED` ...)	`tool_result.is_error`; `stop_reason`

Phiên phụ MỚI	`session_meta.thread_source = guardian_review`, `source.subagent`, `parent_thread_id`; tên file hai ID là phiên rẽ nhánh	`parent_conversation_id`, `nesting_depth` trong conversation_summaries.db	`isSidechain`; model phụ chạy nền trong `cost-state.modelUsage`
Chi phí sẵn có MỚI	Không	Không	`cost-state.totalCostUSD`, `modelUsage.{model}.costUSD` (dùng để đối chiếu)
Khóa chống trùng	`response_id`	id dạng chuỗi ở 1.4.11	`message.id`
Project	`session_meta.cwd`	`workspace_uris` trong conversation_summaries.db	Tên thư mục project
Trạng thái kiểm tra	Đã xác nhận (02/11, 05/11)	Đã xác nhận 02/11; ngày 05/11 thư mục `conversations/` rỗng, conversation_summaries.db rỗng (R-08, OQ-10)	Định dạng đã xác nhận trên phiên Agent SDK 05/11; máy nhóm chưa cài CLI (R-01)

Quy đổi về chuẩn chung:

Trường chuẩn	Codex	Antigravity	Claude Code
`input_tokens` (gồm cache)	`input_tokens`	1.4.2 + 1.4.5	`input_tokens + cache_read + cache_creation`
`cached_tokens`	`cached_input_tokens`	1.4.5	`cache_read_input_tokens`
`cache_write_tokens`	`cache_write_input_tokens`	0	`cache_creation_input_tokens`
`output_tokens` (gồm thinking)	`output_tokens`	1.4.3	`output_tokens`
`thinking_tokens`	`reasoning_output_tokens`	1.4.9	`output_tokens_details.thinking_tokens` SỬA

Phép kiểm tra cho parser (sai thì báo SOURCE_FORMAT_UNSUPPORTED): Codex `total_tokens = input_tokens + output_tokens`; Antigravity `1.4.3 = 1.4.9 + 1.4.10`; Claude Code: các dòng cùng `message.id` phải có cùng usage. Ví dụ thật từ Antigravity: input không cache 5,478, cached 40,743, output 914 (thinking 747 + trả lời 167) → input chuẩn 46,221, total 47,135.

Số đo minh họa ngày 05/11 MỚI v0.9:

- Phiên Codex chính (`gpt-5.6-sol`, effort low, 9 turn, 63 lần gọi): cache hit 97,9%; chi phí input giảm khoảng 88% nhờ cache; thinking 20,4% output; context tăng từ 22,5k lên 111k token mỗi lần gọi (×4,9); 6/35 lệnh lỗi; 0/9 turn lỗi.
- Một phiên tự duyệt Codex (`guardian_review`) dùng khoảng 6,4 triệu token input, lớn hơn phiên chính ở trên (khoảng 4,4 triệu).
- Phiên Claude Code (`claude-opus-5-5`): 461 dòng assistant nhưng 254 phản hồi thật; cache hit 98,7%; thinking 13,5% output; model phụ Haiku chạy nền có chi phí riêng trong `cost-state`.

Phát hiện thêm: log Codex có `rate_limits` (% hạn mức 5 giờ và 7 ngày, loại gói). Quota nằm ngoài phạm vi MVP nhưng có thể làm tính năng sau.

10.5 Giới hạn của phương pháp đo hiệu suất MỚI v0.9

- **Dữ liệu quan sát, không phải thí nghiệm:** người dùng tự chọn model; trong cùng nhóm việc, task giao cho model mạnh vẫn có thể khó hơn. Kết luận so sánh mang tính tham khảo.
- **Nhãn thành công suy ra:** có thể sai, nhất là ở việc không có test. Kiểm soát bằng SR chính/phụ và kiểm chứng với người gán nhãn (§9.3).
- **Phân nhóm việc theo metadata:** chưa kiểm chứng.
- **Giá thay đổi:** CPST phụ thuộc bảng giá; giữ PricingVersion để so sánh được theo thời gian.
- **Nghiên cứu nền:** phần lớn đo trên model 2021–2024; các ngưỡng cần hiệu chỉnh trên dữ liệu thật.

> Nhắc lại: Bạn đã tự đọc hết tài liệu này chưa, hay chỉ đọc tóm tắt của AI? [passage omitted]